在华为 CloudMatrix384 超节点上服务大语言模型

Serving Large Language Models on Huawei CloudMatrix384

Pengfei Zuo 等 48 人 · 华为 & SiliconFlow
arXiv:2506.12708v3 · 2025-06 · CC BY 4.0
中文全文译本 · 2026-10-10

译本说明：本 PDF 为文本排版中文译本（替代方案，非 nature-paper-trans 的逐页版式保留图片型产物——当前环境无 image_gen 生图工具）。译文取自本项目 nature-reader 全文精读产物（术语表锁定、数值已逐条回源核验）；正文图 24 幅、表 10 幅按原文出现位置插入并附中文图注；公式 Eq.(1)–(4) 以 Unicode 文本呈现；参考文献保留英文原文。

术语对照表

英文术语	中文译法	说明
Unified Bus (UB) / 灵衢	统一总线（UB）	华为超节点互连总线，统一内存语义
supernode	超节点	384 NPU + 192 CPU 统一逻辑节点
CloudMatrix384 / CloudMatrix-Infer	不译	系统名/推理服务方案名
prefill / decode	预填充 / 解码	两阶段推理
PDC disaggregation	prefill-解码-缓存分离	peer-to-peer 对等架构
expert parallelism (EP / LEP)	（大规模）专家并行	EP320 = 320 路专家并行
MLA / MTP	多头潜在注意力 / 多 token 预测	DeepSeek 架构特性
microbatch	微批次	流水线Overlap 单元
TPOT / TTFT	每 token 输出时间 / 首 token 时间	时延 SLO 指标
AIV-direct / SDMA	AIV 直连通信 / SDMA	两种跨 NPU 通信机制

FusedDispatch / FusedCombine	不译（融合分发/合并算子）	替换 all-to-all 的融合算子
EMS	弹性内存服务	UB 驱动的分离式内存池
UB plane	UB 平面	与 VPC 平面相对
die	芯粒	Ascend 910 双芯粒架构
scale-up	纵向扩展	相对 scale-out 横向扩展

Pengfei Zuo, Huimin Lin, Junbo Deng, Nan Zou, Xingkun Yang, Yingyu Diao, Weifeng Gao, Ke Xu, Zhangyu Chen, Shirui Lu, Zhao Qiu, Peiyang Li, Xianyu Chang, Zhengzhong Yu, Fangzheng Miao, Jia Zheng, Ying Li, Yuan Feng, Bei Wang, Zaijian Zong, * * * * Mosong Zhou, Wenli Zhou, Houjiang Chen, Xingyu Liao, Yipeng Li, Wenxiao Zhang, Ping Zhu *, Yinggang Wang *, Chuanjie Xiao *, Depeng Liang *, Dong Cao *, Juncheng Liu *, Yongqiang Yang, Xiaolong Bai, Yi Li, Huaguo Xie, Huatao Wu, Zhibin Yu, Lv Chen, Hu Liu, ✉ ✉ Yujun Ding, Haipei Zhu, Jing Xia, Yi Xiong, Zhou Yu, Heng Liao

华为 * SiliconFlow

Abstract

大语言模型（LLM）在参数规模持续增长、混合专家（MoE）架构广泛采用以及上下文长度不断扩展的驱动下快速演进，对 AI 基础设施提出了前所未有的要求。传统 AI 集群日益受到计算强度、内存带宽限制、芯片间通信开销以及严苛时延要求的制约。在真实部署中，系统还须在满足严格服务级目标（SLO）的同时应对多样化、突发性的负载、变长输入和不均衡的专家激活，这些挑战进一步叠加。要突破这些约束，需要一个从根本上重新架构、软硬件协同设计的技术栈。为应对这些挑战，本文介绍华为 CloudMatrix——一种体现华为重塑 AI 基础设施根基这一愿景的下一代 AI 数据中心架构。Huawei CloudMatrix384 是该愿景的首个生产级实现：它将 384 颗昇腾 910（Ascend 910）NPU、192 颗鲲鹏（Kunpeng）CPU 及其他硬件组件整合为一个统一的超节点，通过超高带宽、低时延的统一总线（UB，灵衢）网络互连。与传统层次化设计不同，该架构支持经由 UB 的直接 all-to-all 通信，使算力、内存和网络资源可以被动态池化、统一访问并独立扩展。这些架构特性对大规模 MoE 专家并行、分布式键值（KV）缓存访问等通信密集型操作尤为有利，使 CloudMatrix384 成为下一代 LLM 推理服务的可扩展、高性能基础。为充分释放 CloudMatrix384 的能力，我们提出 CloudMatrix-Infer——一套完整的 LLM 推理服务解决方案，为部署 DeepSeek-R1 等大规模 MoE 模型确立了最佳实践。CloudMatrix-Infer 包含三项核心创新。第一，我们设计了将对等的推理服务架构，把 prefill（预填充）、解码与缓存分离为可独立扩展的资源池。与现有以 KV 缓存为中心的架构不同，该设计通过 UB 网络实现对缓存数据的高带宽、统一访问，从而缓解数据局部性约束、简化任务调度并提升缓存效率。第二，我们设计了利用 UB 网络实现高效 token 分发与专家输出合并的大规模专家并行（EP）策略。该策略支持极高的 EP 并行度（如 EP320），使每个 NPU 芯粒恰好承载一个专家，从而实现低解码时延。最后，我们提出一组为 CloudMatrix384 量身定制的硬件感知优化，包括高度优化的算子、基于微批次的流水线以及 INT8 量化，以增强执行效率和资源利用率。基于 DeepSeek-R1 模型的大量评估表明，CloudMatrix-Infer 在不牺牲精度的前提下实现了业界领先的效率：其 prefill 吞吐量达每 NPU 6,688 tokens/s，解码吞吐量达每 NPU 1,943 tokens/s（TPOT < 50 ms），分别对应 prefill 4.45 tokens/s/TFLOPS、解码 1.29 tokens/s/TFLOPS 的计算效率，均超过 SGLang 在 NVIDIA H100 与 DeepSeek 在 NVIDIA H800 上已发表的结果。此外，CloudMatrix-Infer 还

1 引言

近年来，大语言模型（LLM）的格局发生了深刻变革，其背后是几大决定性趋势：参数规模的指数级增长、混合专家（MoE）架构的广泛采用，以及上下文长度的显著扩展 [33]。DeepSeek-R1 [13]、LLaMA-4 [39]、Qwen-3 [49] 等现代 LLM 的参数量普遍达到数千亿乃至上万亿，对计算能力和内存能力提出了前所未有的要求。MoE 模型通过按 token 选择性激活一小部分专家引入结构性稀疏，在提升规模化效率的同时，也带来了专家路由与同步方面新的系统级挑战 [18, 30, 34]。与此同时，上下文窗口已从数万 token 扩展到超过一百万 token [21, 45]，给注意力计算和键值（KV）缓存存储带来巨大压力。KV 缓存总容量随并发用户数线性增长，如何在整个系统中分布、放置和访问 KV 缓存以支撑高效推理，构成了重要约束。这些趋势共同给 AI 基础设施带来巨大压力——既需要海量算力、高内存容量与带宽、密集的芯片间通信，又要满足严苛的时延约束，最终将传统 AI 集群推向其可扩展性极限。

在生产环境中，真实负载的动态性与异构性使此类模型的推理服务进一步复杂化。具体而言，LLM 推理服务系统必须应对变长的用户输入、跨 token 的不均衡专家激活以及高度突发的用户查询，同时维持严苛的时延与吞吐量目标。满足这些需求绝不仅仅是简单扩大硬件资源规模，而是需要全面的软硬件协同设计：既要有紧密集成的算力、内存与网络硬件资源，也要辅以智能任务调度、自适应运行时编排，以及能够动态响应模型结构演进与负载波动的弹性资源管理策略。总而言之，随着 LLM 在规模和复杂性上持续增长，从根本上重新构想 AI 基础设施的设计已成为必然。

为回应这些需求，我们提出华为 CloudMatrix——一种建立在完全对等的高带宽互连与细粒度资源分离原则之上的下一代 AI 数据中心架构。我们着重介绍 CloudMatrix384，它是这一创新架构理念的首个生产级实现。CloudMatrix384 是面向大规模 AI 负载专门构建的 AI 超节点，采用完全对等互连的硬件设计。它由 384 颗 Ascend 910 NPU 和 192 颗 Kunpeng CPU 组成，通过名为统一总线（UB，灵衢）的超高带宽、低时延网络互连。尤其重要的是，该 UB 网络支持在所有算力与内存组件之间进行直接的 all-to-all 数据交换。与节点内和节点间互连带宽不均衡的传统层次化架构不同，CloudMatrix384 使整个超节点能够作为一个逻辑上统一、紧耦合的计算实体运行，体现了“一切皆可池化、被平等对待、自由组合”的完全对等原则。这些架构特性对大规模 MoE 专家并行、分布式 KV 缓存访问等通信密集型操作尤为有利，使 CloudMatrix384 成为下一代 LLM 推理服务的可扩展、高性能基础。

CloudMatrix384 的最初设计早于 MoE 架构的广泛普及 [15, 39, 49]，因为这样一个完整超节点系统的设计与部署通常耗时数年。尽管如此，CloudMatrix384 的构建目标正是提升互连带宽与通信效率——这是扩展大规模训练与推理负载所必需的核心能力。DeepSeek-R1 [13] 等大规模 MoE 模型的出现验证了这一

架构前瞻性，并凸显出在现代 LLM 部署中，通信带宽与计算、内存带宽能力同等关键。

为充分挖掘 CloudMatrix384 的能力，我们提出 CloudMatrix-Infer——一套完整的 LLM 推理服务解决方案，代表了部署 DeepSeek-R1 等大规模 MoE 模型的最佳实践。CloudMatrix-Infer 引入三项核心创新。

第一，我们设计了一种新颖的对等推理服务架构，将 LLM 推理系统分离为三个独立子系统：prefill（预填充）、解码与缓存。所谓对等，是指这三个子系统作为地位平等且相互独立的资源池运行，而非围绕某个中心化实体进行编排。这与传统以 KV 缓存为中心的架构 [41, 48] 形成鲜明对比——后者将请求调度与已缓存 KV 块的物理放置紧耦合，既增加了调度复杂性，又限制了资源分配的灵活性。借助

高带宽 UB 互连，我们构建了一个跨系统提供共享缓存服务的分离式内存池。prefill 与解码子系统中的所有 NPU 都能以对等方式、以统一的带宽和时延直接从该池访问已缓存的 KV 数据，而无论这些数据最初在何处计算或存储。这一设计将请求调度与数据局部性解耦，大幅简化任务调度逻辑、提升缓存效率，并提高整体系统资源利用率。

第二，我们开发了专为 MoE 模型优化的大规模专家并行（LEP）策略。LEP 的核心原则是汇聚大量 NPU 的算力与内存带宽，以加速注意力与前馈网络的计算。这种加速的代价是 token 分发与专家输出合并带来的通信开销增加。然而，CloudMatrix384 的超高带宽 UB 互连确保该通信时延始终有界，不会成为主导性能瓶颈。此外，我们的 LEP 策略支持极高的专家并行度，例如 EP320，使每个 NPU 芯粒恰好为 DeepSeek-R1 承载一个专家。这一配置最大限度减少了同一 rank 内专家之间的串行执行，从而降低整体 MoE 执行时延。这些设计选择共同实现了低解码时延，并为基于 MoE 的推理带来显著的端到端性能收益。

最后，我们提出一套明确为 CloudMatrix384 量身定制的硬件感知优化，包括高度优化的 Ascend 算子、基于微批次的流水线以及 INT8 量化。优化后的算子加速端到端执行，并为 LEP 提供高效支撑。基于微批次的流水线设计通过重叠处理两个连续微批次，同时提升资源利用率与系统吞吐量。INT8 量化提高计算效率，并大幅降低内存带宽消耗。总体而言，这些优化与 CloudMatrix384 的独特架构特性——包括片上 cube、向量与通信引擎，以及高带宽 UB 互连——协同设计，以最大化整体执行效率。

我们在 CloudMatrix384 上使用 6710 亿参数的 DeepSeek-R1 模型对 CloudMatrix-Infer 进行评估，结果展示了出色的性能与硬件效率。prefill 阶段，在 4K 提示长度下，CloudMatrix-Infer 达到每 NPU 6,688 tokens/s 的吞吐量，折合计算效率 4.45 tokens/s/TFLOPS。解码阶段，在 4K KV 缓存长度下，系统维持每 NPU 1,943 tokens/s 的吞吐量，同时将每 token 输出时间（TPOT）持续控制在 50 ms 以下，对应计算效率 1.29 tokens/s/TFLOPS。值得注意的是，两个阶段的计算效率指标均超过 SGLang 在 NVIDIA H100、DeepSeek 在 NVIDIA H800 等领先框架的已发表结果。CloudMatrix-Infer 还展现出对吞吐量-时延这一根本性折中的有效管理：为满足更严格的 sub-15 ms TPOT 要求，CloudMatrix-Infer 可动态调整批大小，实现每 NPU 538 tokens/s 的解码吞吐量。这凸显了其可预测的性能与适应性

在变化的服务级目标（SLO）之下。此外，INT8 量化在 16 个代表性基准测试上保持了与 DeepSeek-R1 官方 API 相当的精度。这些结果共同确立了 CloudMatrix384 与我们的对等（peer-to-peer）推理服务方案 CloudMatrix-Infer 相结合，构成一个可扩展、高吞吐、生产级的大规模 LLM 部署平台。

本文其余部分组织如下。第 2 节首先回顾 LLM 的关键趋势，并给出传统数据中心基础设施所固有的系统级挑战。第 3 节阐述华为 CloudMatrix 的愿景并详述 CloudMatrix384 的设计。随后在第 4 节介绍 CloudMatrix-Infer 所采用的推理服务系统架构与优化技术。第 5 节给出详尽的性能评估。最后，第 6 节展望未来的研究方向，第 7 节对全文进行总结。 2 LLM 趋势及其对数据中心基础设施的挑战 本节首先讨论正在重塑 AI 计算格局的大语言模型（LLM）设计新趋势（§2.1），随后给出这些趋势给传统数据中心基础设施带来的相应系统级挑战（§2.2）。

2.1 LLM 趋势

LLM 的快速演进呈现出三大显著趋势：模型参数量不断攀升、通过混合专家（MoE）架构引入稀疏性，以及上下文窗口的持续扩展。这些进展旨在提升模型性能，同时兼顾计算效率与可扩展性。

参数量持续攀升。经验缩放定律表明，增大 LLM 的参数数量可以提升模型在各类任务上的性能 [33]。近期的进展印证了这一趋势：Meta 的 Llama 4 Behemoth 拥有近 2 万亿参数，其同系列的 Llama 4 Maverick 包含 4000 亿参数 [39]。DeepSeek-AI 开发的 DeepSeek-V3 包含 6710 亿参数 [15]。Google 的 PaLM 模型包含 5400 亿参数 [8]，xAI 的 Grok-1 拥有 3140 亿参数 [54]。这些模型凸显了业界持续扩大 LLM 规模以增强推理、多语言理解与代码生成能力的努力。

以 MoE（混合专家）实现稀疏化。为控制不断攀升的训练与推理成本，现代 LLM 日益采用稀疏激活的 MoE 架构，将模型总容量与每 token 的计算需求解耦。代表性实现包括 Mixtral 8×7B：总参数量 467 亿，但通过将每个 token 路由到每层 8 个专家中的 2 个，每 token 仅激活 129 亿参数，在保持计算效率的同时取得与 GPT-3.5 相当的性能 [32]。Databricks 的 DBRX 采用细粒度 MoE 架构，总参数 1320 亿，通过从 16 个更小的专家中选出 4 个，每 token 激活 360 亿参数，从而提升吞吐并降低时延 [19]。Meta 的 Llama 4 系列将 MoE 引入开源模型，其中 Llama 4 Maverick 使用 128 个专家、Llama 4 Scout 使用 16 个专家，二者每 token 激活参数均为 170 亿 [39]。DeepSeek-V3 在前代基础上将每层路由专家数从 160 增至 256，在不按比例增加计算负载的前提下增强了模型容量 [14, 15]。阿里巴巴的 Qwen3-235B 模型包含 128 个专家，每 token 激活 220 亿参数，在大规模容量与计算效率之间取得平衡 [49]。华为的 Pangu Ultra MoE 模型规模达 7180 亿参数，每 token 激活 390 亿参数；它采用每层 256 个专家的 MoE 架构，其中每 token 激活 8 个 [52]。这些模型共同表明，LLM 的扩展策略正在发生范式转变：为获得更高的性能与效率，架构稀疏性比单纯堆砌参数量更为关键。

上下文窗口的扩展。LLM 上下文窗口的扩大使其能够处理更长的序列，这对需要长程推理与连贯性的任务至关重要。近期进展反映了这一转变：OpenAI 的 GPT-4.5 支持 128,000 token 的上下文窗口 [45]，而 Google 的 Gemini 2.5 Pro 提供最高 100 万 token 的上下文窗口 [21]。LongBench [6] 等基准量化了扩展上下文窗口对问答、摘要与多步推理等任务的收益。然而，向 LLM 输入长提示词会显著推高计算成本并拉长推理时延。为缓解这些成本，生产系统采用上下文缓存：将较早提示词分段生成的键值（KV）块存储起来，并在后续轮次或请求中复用。这一做法消除了提示词的冗余注意力计算，从而降低时延、提升效率 [20, 48]。

2.2 数据中心基础设施面临的挑战

这些 LLM 趋势对底层数据中心基础设施提出了严苛的新要求。随着模型能力不断扩张，它们推动着日益复杂工作负载的涌现，例如重推理型推理任务、基于强化学习（RL）的后训练、交互式媒体生成以及自主 AI 智能体。这些应用不仅需要显著更大的算力与内存容量，还要求基础设施进行根本性的架构重构，以支持高带宽通信、低时延存储访问与持续稳定的吞吐量，同时要在动态、异构的真实条件下满足严格的服务级时延目标。在此背景下，我们识别出四个关键的系统级挑战：

挑战 1：扩展通信密集型并行。随着模型规模增长，最先进的 AI 模型常常超出单个计算节点的容量，需要多节点并行策略。现有 AI 集群虽支持经 RDMA 网络的节点间通信，但其带宽与拓扑通常面向节点间流量不大的数据并行或流水线并行（DP/PP）优化。而张量并行（TP）与专家并行（EP）要求频繁、细粒度、低时延的通信，这类通信难以高效地跨节点边界扩展。这迫使许多部署将 TP/EP 组限制在单个计算节点内，制约了可扩展性。

挑战 2：在异构 AI 负载下维持高利用率。现代 AI 负载的资源需求高度多样且动态变化。训练通常属于计算密集型，推理（尤其是 LLM 的解码阶段）常受内存带宽限制，而自动驾驶模型训练等任务则涉及大量 CPU 侧数据预处理。固定的节点配置无法高效适应这种多样性，往往导致过度配置或资源利用率

低下。为最大化效率与适应性，现代 AI 基础设施必须支持 NPU、CPU、内存等异构资源的动态、细粒度组合，以匹配每种负载的具体需求。

挑战 3：支持 AI 与数据密集型负载的融合执行。AI 工作流日益与传统数据密集型操作交汇，如数据摄取、预处理、检索、分析与仿真。与此同时，数据库、大数据、高性能计算（HPC）等通用负载自身也在逐步融入 AI 能力。这些融合执行模式要求高吞吐、低时延的通信与灵活的资源编排。然而，主要为传统通用负载优化的既有数据中心基础设施难以满足这些严苛要求。要实现 AI 与数据密集型任务的高效融合，需要一种从根本上全新的基础设施。

挑战 4：提供内存级存储性能。现代 AI 流水线所处理的数据规模空前，远超传统存储系统的能力。诸如

摄取 PB 级数据集、管理多 TB 模型检查点，以及支撑时延敏感的推理（尤其是涉及大容量 KV 缓存与检索增强生成（RAG）模块的场景）等任务，都要求存储子系统具备内存级的带宽、时延与 IOPS。围绕磁盘访问模式设计的传统存储层级经常成为性能瓶颈，导致 NPU 因数据供给不足而利用率低下。 3 华为 CloudMatrix 为应对 AI 负载中的这些新兴挑战，华为提出 CloudMatrix——一种旨在重塑 AI 基础设施根基的新一代 AI 数据中心架构。这一架构愿景的核心，是构建一个统一、紧耦合的计算互联网络，以高效支撑现代 AI 应用的规模、异构性与通信需求。CloudMatrix384 是该愿景的首个生产级实现，交付了一个面向大规模 AI 负载优化的专用平台。

本节首先概述 CloudMatrix 的愿景（§3.1），随后总览 CloudMatrix384 的全对等硬件架构（§3.2），继而拆解其核心硬件组件（§3.3）。接着介绍使 CloudMatrix 得以部署在华为云的软件栈（§3.4）。最后，我们分析其高效推理服务 DeepSeek-R1 等大规模 MoE 模型的适配性（§3.5）。

3.1 华为 CloudMatrix 的愿景

为应对现代大规模 AI 工作负载不断升级的需求，华为推出了 CloudMatrix——一种开创性的下一代 AI 数据中心架构。该架构围绕完全对等的高带宽互联互通与细粒度资源分离式设计这两项原则精心打造。如 Figure 1 的概念性示意所示，CloudMatrix 将

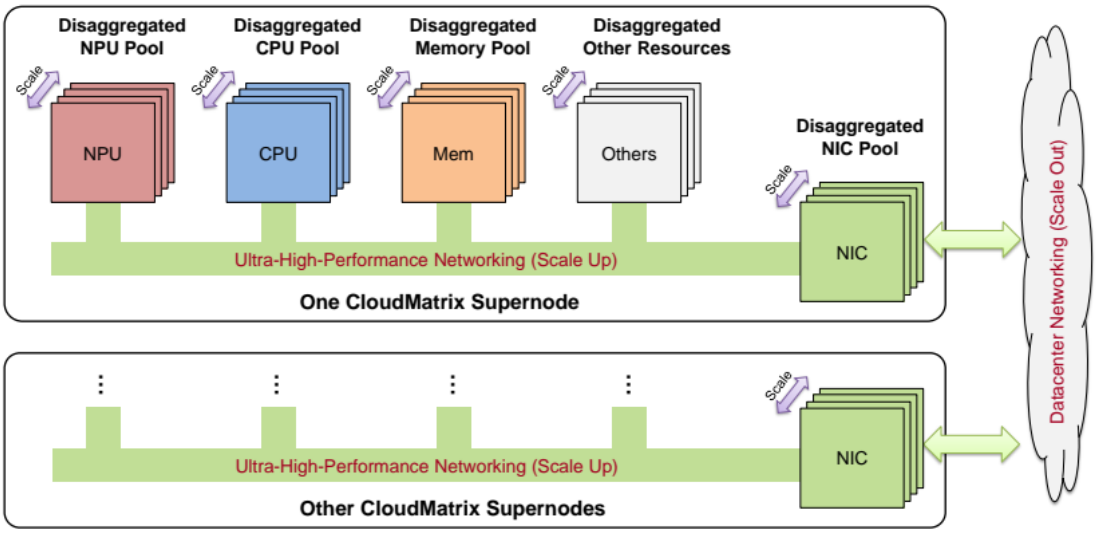


Fig. 1. 华为 CloudMatrix 架构愿景从底层重新构想 AI 数据中心基础设施。它打破传统的烟囱式（siloed）设计，在统一的超高性能网络之上实现 CPU、NPU、内存、网卡（NIC）等资源的完全对等分离与池化，为可扩展的 AI 原生数据中心奠定基础。

来源：p.8 C001（原文 Fig. 1）

超越了传统以 CPU 为中心的分层设计。它支持所有异构系统组件之间直接的高性能通信，包括 NPU、CPU、DRAM、SSD、网卡与领域专用加速器，尤为关键的是无需 CPU 中转。

该架构的核心是超高带宽、低时延的*统一总线（Unified Bus，UB，灵衢）*网络，可实现高效的全系统数据搬运与协同。在这一互连底座之上，CloudMatrix 提供四项基础能力，共同定义了 AI 原生基础设施的新范式：面向 TP/EP 的可扩展通信。(1) UB 互连支持跨 NPU 的直接、高吞吐对等通信，使 TP 与 EP 组能够扩展到单个节点的边界之外。这消除了节点间瓶颈，使大模型得以高效分布到整个超节点上。面向异构负载的灵活资源组合。(2) CloudMatrix 将 CPU、NPU 与内存分离为相互独立、各自池化的资源，实现细粒度、按负载驱动的组合。这种灵活性允许依据负载需求进行细粒度资源分配，例如内存充裕的缓存节点、CPU 密集的预处理节点，使部署摆脱固定节点配置或基于 PCIe 的主机-设备耦合。

(3)面向融合负载的统一基础设施。高带宽 UB 网络在单一 scale-up（纵向扩展）基础设施内同时支撑 AI 与数据密集型应用，使 LLM 推理、训练、仿真与分析负载得以融合执行——这正日益成为混合化 AI 流水线的普遍要求。基于分离式内存池的内存级存储。(4) CloudMatrix 将全集群 CPU 侧 DRAM 聚合为一个可经 UB 访问的共享高性能内存池。该底座支撑弹性内存服务（EMS）[26] 等服务，通过消除传统 I/O 瓶颈，加速 KV 缓存复用、参数加载与模型检查点等时延敏感操作。

下文将描述的华为 CloudMatrix384 正是这一架构愿景的首个生产级实现，专为在规模化场景下满足下一代 AI 负载的计算、内存与通信需求而打造。

3.2 CloudMatrix384 概览：全对等硬件架构

CloudMatrix384 被设计为一个 AI 超节点，集成了 384 个昇腾 910（Ascend 910）神经网络处理器（NPU）和 192 个鲲鹏（Kunpeng）中央处理器（CPU），如 Figure 2 所示。CloudMatrix384 的一项标志性特性是其 *对等、全互联、超高带宽的网络*，通过统一总线（UB，灵衢）协议将所有 NPU 和

CPU 连接在一起。CloudMatrix384 的 UB 设计是文献 [38] 所提 UB-Mesh 的先导。384 个 NPU 与 192 个 CPU 中的每一个都经由 UB 交换机连接，使节点间通信性能接近节点内水平：节点间带宽劣化低于 3%，节点间时延增加不超过 1 μs。鉴于现代 AI 工作负载主要受带宽约束而非时延敏感，这一边际时延开销对 AI 任务的端到端性能影响可以忽略。总体而言，该设计使 CloudMatrix384 能够作为一个紧耦合的大规模逻辑节点运行，具备全局可寻址的计算与内存，从而支持统一的资源池化与高效的工作负载编排。

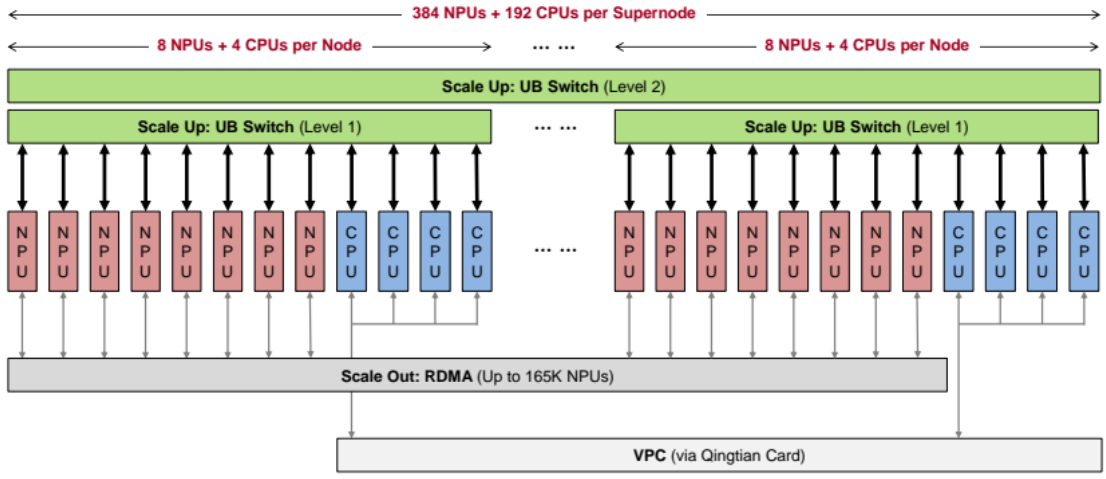


Fig. 2. CloudMatrix384 超节点的对等硬件架构：超节点内部通过超高带宽统一总线（UB，灵衢）平面进行 scale-up（纵向扩展），超节点之间通过 RDMA 平面通信，并通过虚拟私有云（VPC）平面接入数据中心网络。图中所有网络带宽数值均指单向带宽。

来源：p.10 C002（原文 Fig. 2）

为支撑多样的流量模式并保持与传统数据中心网络的兼容，CloudMatrix384 引入了三个相互独立又互为补充的网络平面：

1) UB 平面。UB 平面构成超节点内主要的超高带宽 scale-up 互联网络，以无阻塞的 all-to-all 通信拓扑直接互连全部 384 个 NPU 与 192 个 CPU。UB 支持：(1) 高效实现 TP、EP 等细粒度并行策略，

且不受节点边界约束；(2) 对池化内存（同时涵盖 CPU 与 NPU 内存）的快速对等访问，这对高效缓存模型权重与 KV 缓存至关重要。

2) RDMA 平面。RDMA 平面负责跨 CloudMatrix384 超节点的 scale-out（横向扩展）通信以及与外部 RDMA 兼容系统的互联。目前它采用融合以太网上的 RDMA（RoCE），以兼容标准 RDMA 协议栈。1 仅 NPU 参与该平面，从而将 RDMA 流量与控制及存储操作相互隔离。其主要功能包括：(1) 推理期间在 prefill（预填充）NPU 与解码 NPU 之间高速传输活跃 KV 缓存数据；(2) 支持使用兼容 RDMA 框架的分布式训练与推理；(3) 在多集群部署中提供跨超节点的低时延互连。

3) VPC 平面。虚拟私有云（VPC）平面经由高速网卡（华为*擎天（Qingtian）*卡）将 CloudMatrix384 超节点接入更广的数据中心网络。它运行于标准以太网与 IP 协议之上，并可选地叠加以太网上的 UB（UB-over-Ethernet，UBoE）增强。VPC 平面承担：(1) 部署、监控、调度等管理与控制面操作；(2) 访问持久存储，包括对象存储（OBS）、弹性卷服务（EVS）与可扩展文件系统服务（SFS）；(3) 来自驻留 CPU 之负载（如数据库与用户界面）的外部服务通信。

尽管如图 1 所示，CloudMatrix 的长期愿景是将 RDMA 与 VPC 平面融合为单一的统一平面，但当前 CloudMatrix384 仍将二者分离，以确保与传统数据中心基础设施的向后兼容。我们将在 §6.1.1 讨论统一 VPC 与 RDMA 平面的未来工作。

3.3 硬件组件

3.3.1 昇腾 910（Ascend 910）芯片

CloudMatrix384 的核心是海思 Ascend 910 NPU——华为 2024 年一代的旗舰 AI 加速器。Ascend 910 采用双芯粒封装：两颗相同的计算芯粒协同封装，共享八个封装内内存堆栈，并由高带宽的跨芯粒互连 fabric 相连，如 Figure 3 所示。每颗芯粒包含 24 个面向矩阵与卷积工作负载优化的 AI Cube（AIC）核心，以及 48 个用于逐元素运算的 AI Vector（AIV）核心。所有计算引擎均支持 FP16/BF16 与 INT8 数据类型。8 比特量化可以 INT8 精度实现，在无需专用 FP8 硬件支持的情况下获得与原生 FP8 相当的计算效率。两颗芯粒经由封装内互连通信。每颗 Ascend 910 芯粒对接两个不同的网络平面。*1) UB 平面*：芯粒集成七个高速收发器，接入 scale-up（纵向扩展）UB 平面。*2) RDMA 平面*：此外，每颗芯粒还为 scale-out RDMA 平面提供专用接口。

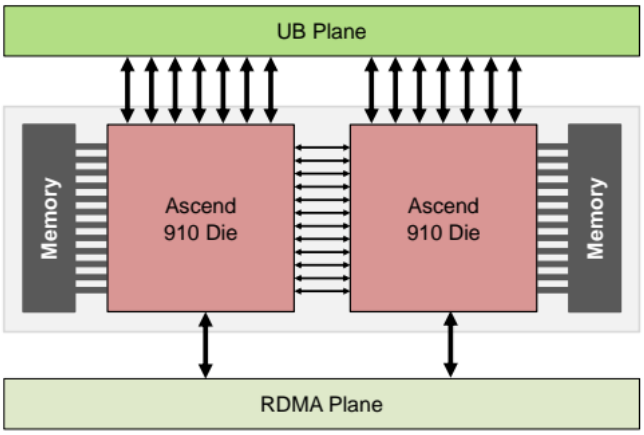


Fig. 3. 华为昇腾 910（Ascend 910）芯片的逻辑概览，重点展示其双芯粒架构。图中所有网络带宽数值均指单向带宽。

来源：p.11 C003（原文 Fig. 3）

3.3.2 Ascend 910 节点

CloudMatrix384 的每个计算节点集成 8 个 Ascend 910 NPU、4 个鲲鹏 CPU 以及 7 个板载 UB 交换芯片，如 Figure 4 所示。12 个处理器（8 个 NPU 与 4 个 CPU）经 UB 链路接入这些板载交换机，在节点内构成单层 *UB 平面*。每个板载 UB 交换芯片上连至超节点 fabric 的下一级交换层。仅 NPU 参与第二层 *RDMA 平面*。

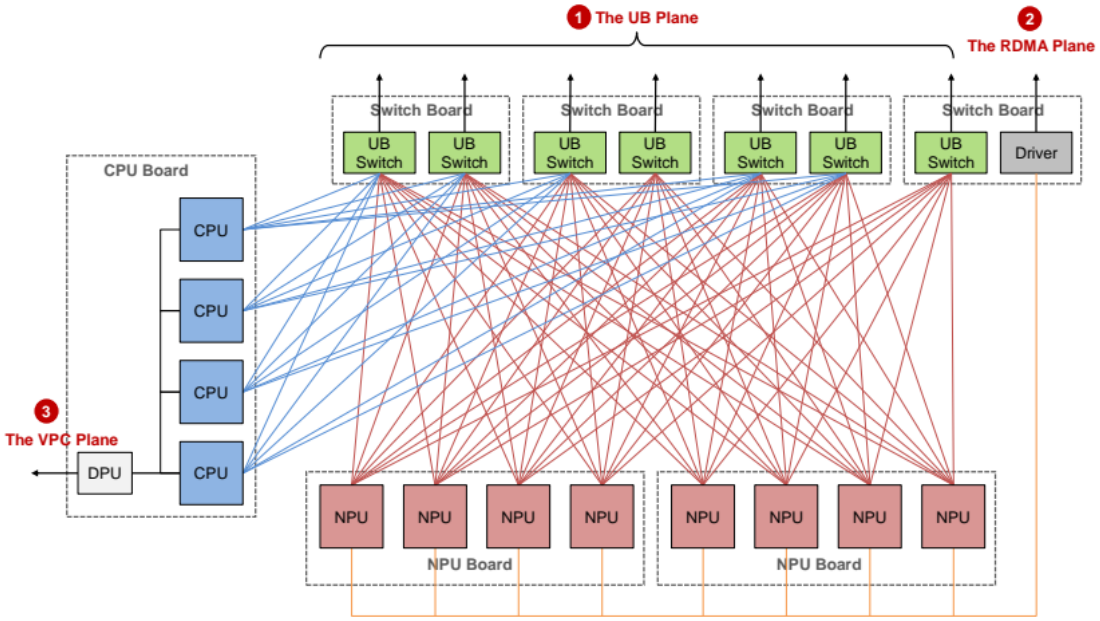


Fig. 4. CloudMatrix384 中单个 Ascend 910 节点的逻辑概览。图中所有网络带宽数值均指单向带宽。

来源：p.12 C004（原文 Fig. 4）

在 CPU 复合体中，四路鲲鹏（Kunpeng）CPU 插槽经全互连（full-mesh）NUMA 拓扑互连，实现对所有 CPU 侧 DRAM 的统一内存访问。其中一颗 CPU 承载节点的*擎天*卡——一款专用数据处理器（DPU），它不仅集成高速网络接口，还承担关键的节点级资源管理职能。该*擎天*卡是节点南北向流量的主要出口，与第三个独立的网络平面——数据中心的*VPC 平面*——对接。1 另一种设计方案 *RDMA over UB* 利用 UB 对远程内存访问的原生支持，为超节点内与超节点间通信构建统一的 UB 域。该方案语义更简洁，并可规避协议转换开销，但当前实现选择 RoCE，以确保与既有 RDMA 库及工具链的即时兼容。

3.3.3 UB 交换机系统

CloudMatrix384 超节点横跨 16 个机柜：12 个 *计算机柜*合计承载 48 个 Ascend 910 节点（共 384 个 NPU），另有 4 个 *通信机柜*。通信机柜承载互联超节点内全部节点的二级（L2）UB 交换机。

图 5 展示了板载第一级（L1）UB 交换机（位于每个 Ascend 910 节点内部）与机柜级 L2 UB 交换机之间的拓扑。该网络按无阻塞设计，意味着 L2 交换层*不存在*带宽收敛（oversubscription）。L2 交换机被划分为 7 个独立的*子平面*。每个子平面包含 16 颗 L2 UB 交换芯片，每颗 L2 交换芯片提供 48 个端口。

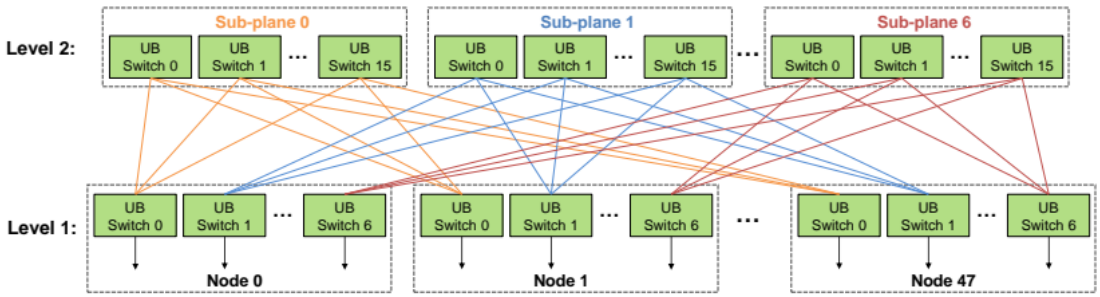


Fig. 5. CloudMatrix384 中的 UB 交换系统。图中所有网络带宽数值均指单向带宽。

来源：p.13 C005（原文 Fig. 5）

在每个节点内部，7 颗板载 L1 UB 交换芯片与这 7 个 L2 子平面一一对应。每颗 L1 交换芯片通过 16 条链路扇出（通往其对应子平面中每颗 L2 交换芯片各一条链路）。这一配置确保节点通往 L2 网络的聚合上行带宽与其内部 UB 容量精确匹配，从而在整个超节点范围内保持无阻塞特性。

3.4 软件栈

3.4.1 面向 Ascend NPU 的 CANN

华为为昇腾 NPU 打造了完备的软件生态，称为神经网络计算架构（CANN）[29]。CANN 充当中间软件层，使上层 AI 框架（如 PyTorch [46] 与 TensorFlow [2]）与昇腾 NPU 底层硬件接口之间实现高效集成。CANN 将这些框架生成的抽象计算图翻译为优化后的硬件可执行指令，从而简化开发者与昇腾硬件的交互、促进软硬协同设计，并力求充分释放应用在昇腾架构上的性能。

CANN 架构。CANN 软件栈（图 6）由三个主要层次构成：驱动、运行时与库，其架构与 NVIDIA 的 CUDA 生态类似 [40]。

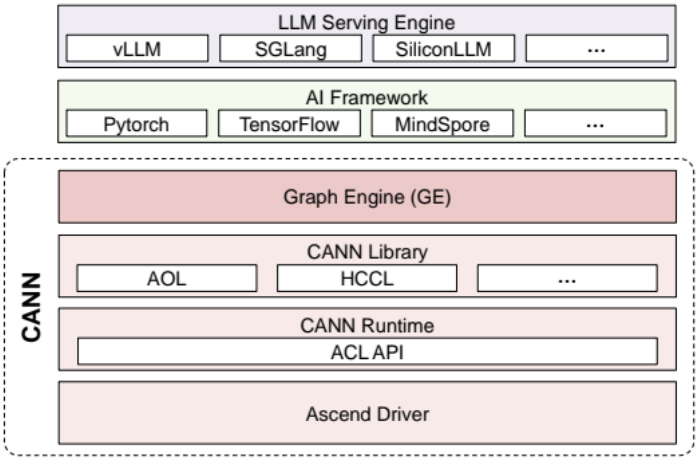


Fig. 6. 面向华为 Ascend NPU 的 CANN 软件栈。

来源：p.14 C006（原文 Fig. 6）

*1) 驱动层：*处于最底层，昇腾 NPU 驱动由内核模块与固件构成，充当操作系统与 Ascend NPU 之间的底层接口。它管理关键的硬件交互，包括设备初始化、资源分配（内存、流）、命令调度以及 NPU 间通信的建立。

*2) 运行时层：*CANN Runtime 是 Ascend NPU 上应用的核心执行引擎。它监管应用生命周期、编排模型计算，并为模型与算子提供全面的设备控制、内存管理与执行管理。这些功能主要经昇腾计算语言（ACL）API 访问。

*3) 库层：*该层提供一整套高度优化的软件组件，用于加速多样的 AI 负载。关键要素包括领域专用加速库（AOL）、面向分布式任务的华为集合通信库（HCCL）、内置大量预优化内核的算子包（OPP），以及神经网络加速引擎（NNAE）与离线推理引擎（NNRT）。此外还支持自定义算子开发（如通过 Ascend C）及与第三方库的集成，以进一步增强其能力。

在核心层之外，*图引擎（GE）*负责编译并优化来自 PyTorch、TensorFlow、MindSpore 等框架的计算图 [28]。它通过算子融合、内存规划、动态 shape 处理与调度等全图优化，在高层次模型与底层执行之间架设桥梁。这些优化降低了开销，提升了在 Ascend NPU 上的执行效率。

框架集成。CANN 对主流 AI 框架提供广泛支持，显著降低了在既有与全新 AI 项目中采用 Ascend NPU 的门槛：• *PyTorch：*借助 PyTorch Ascend 适配器（torch_npu）[4]，开发者可在现有 PyTorch 工作流中无缝利用 Ascend NPU 加速。华为提供预构建 Python wheel 包以简化安装、覆盖 API 兼容性与最佳实践的完备文档，以及将 CUDA 代码迁移至 CANN 的简化工具或指南。• *TensorFlow：*CANN 的 TF_Adapter [5] 将 Ascend 加速能力直接集成进 TensorFlow 框架，使基于 TensorFlow 的 AI 项目只需极少代码改动即可获得高性能与顺畅接入。• *ONNX：*华为为 ONNX Runtime 提供了专用的 CANN execution provider [43]，可高效执行以开放神经网络交换（ONNX）格式导出的模型 [42]，在包含 Ascend NPU 的异构硬件环境中实现广泛的模型兼容与顺畅部署。

• *MindSpore：*由华为内部开发，提供与昇腾硬件的原生且深度优化的集成。该框架旨在华为 AI 生态内提供潜在的更优性能与易用性，是一种紧耦合的软硬一体方案。

综上，CANN 提供了覆盖驱动、运行时与库的垂直整合软件栈，可媲美 NVIDIA 的 CUDA，同时针对 Ascend NPU 定制。其 GE 将全图表示编译为高度优化的执行计划，丰富的框架适配器使既有负载的移植几乎毫无摩擦。这些组件相辅相成，使开发者以极少的代码改动即可驾驭昇腾硬件，并在广泛的 AI 应用中达到接近峰值的设备性能。

3.4.2 面向云部署的基础设施软件

为使 CloudMatrix384 能够部署于云环境，华为云提供了一整套完善的基础设施软件，包括 MatrixResource、MatrixLink、MatrixCompute 与 MatrixContainer，用于抽象硬件复杂性，并通过标准云 API 实现无缝的资源编排，如 Figure 7 所示。

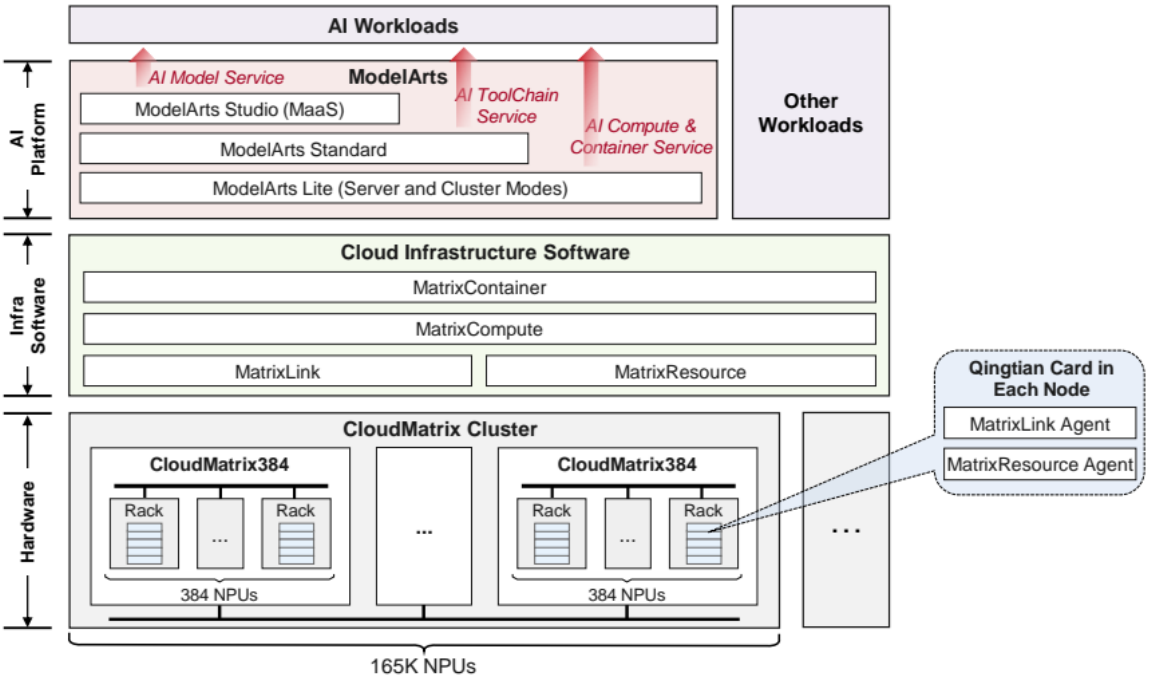


Fig. 7. 用于部署 CloudMatrix384 的云基础设施软件栈。

来源：p.15 C007（原文 Fig. 7）

MatrixResource 负责超节点内的物理资源供给，包括基于拓扑感知调度的计算实例分配。实例供给任务由运行在 CloudMatrix384 每个计算节点*擎天*卡上的 MatrixResource 代理执行。

MatrixLink 为 UB 与 RDMA 网络提供面向服务的组网能力，支持 QoS 保障与动态路由。它管理链路级配置，并支持网络感知的负载放置以获取最优通信效率。这些任务同样由每个计算节点*擎天*卡上的 MatrixLink 代理执行。

MatrixCompute 统筹 CloudMatrix 实例的生命周期，覆盖裸金属供给、自动扩缩容与故障恢复。它跨多个物理节点编排资源组合，构建紧耦合的*逻辑超节点实例*。

MatrixContainer 提供基于 Kubernetes 的容器服务，并辅以拓扑感知调度，以充分释放 CloudMatrix 高性能互连的潜力。用户可使用熟悉的容器化工作流部署分布式 AI 负载。

ModelArts 位于基础设施栈的顶层，提供端到端 AI 平台服务 [27]。它包含：*ModelArts Lite*，用于通过裸金属与容器化

环境直接访问昇腾硬件；*ModelArts Standard*，支持完整的 AI 开发与 MLOps 流水线；*ModelArts Studio*，提供模型即服务（MaaS）能力，用于 LLM 及其他模型的快速部署与定制。

这些组件相辅相成，使用户能够在 CloudMatrix384 上高效构建并部署大规模 AI 应用，在屏蔽底层复杂性的同时保持性能。

3.5 面向 DeepSeek 模型的适配性分析

3.5.1 DeepSeek 模型及其在 NVIDIA H800 上的部署

DeepSeek-AI 已成为 LLM 领域的重要力量，尤其是 DeepSeek-V3 与 R1 两个模型，它们共享一套面向高效训练与推理优化的架构 [13, 15]。这些模型集成了多项系统级创新：671B 参数的混合专家（MoE）架构，在 256 个路由专家中采用 top-8 路由，每 token 仅激活 37B 参数；多头潜在注意力（MLA），可将 KV 缓存大小最多缩减 93.3%；多 token 预测（MTP），支持带解码时验证的多 token 生成；以及 FP8 量化，在保持精度的同时提升性能。总之，DeepSeek 系列模型体现了一种以训练与推理效率为核心的设计哲学。这些创新共同使模型能够以更低的计算与内存需求产出高质量结果。

DeepSeek 将其 V3 与 R1 模型部署于 NVIDIA H800 GPU 集群，每颗 GPU 配备 80 GB 内存，节点内经 NVLink 互连，跨节点采用 400 Gbps InfiniBand [11]。该部署采用分离式 prefill-解码架构。prefill 阶段，DeepSeek 将四个 H800 节点（共 32 颗 GPU）组织为一个部署单元。在每个单元内，256 个路由专家被策略性分布到各 GPU，每颗 GPU 承载 9 个路由专家与 1 个共享专家。该配置记作 *DP32+EP32*，在 32 颗 GPU 间采用专家并行（EP），而共享专家与多头潜在注意力（MLA）机制则经

跨同一组 GPU 的数据并行（DP）进行复制。解码阶段，DeepSeek 将并行规模进一步扩展为 *DP144+EP144*，编组 18 个节点、共 144 颗 GPU。在这一更大规模的部署下，每颗 GPU 管理 2 个路由专家与 1 个共享专家，并维持全系统 32 份路由专家副本的冗余。

为优化吞吐与时延，DeepSeek 采用双微批次流水线策略，使计算与 all-to-all 通信高效重叠。具体而言，当一个微批次参与 MoE 相关的 token 分发与合并时，下一个微批次同时执行本地注意力或 MLP 计算。

这一精心编排的部署带来了可观的吞吐收益。prefill 期间每颗 H800 GPU 最高可达 9,213 tokens/s，在 56.3% 的上下文缓存命中率加持下，剔除缓存命中后有效吞吐为 4,026 tokens/s。解码期间，每颗 GPU 平均维持 1,850 tokens/s 的吞吐。

这些性能优化策略为随后在华为 CloudMatrix384 上部署 DeepSeek 模型提供了宝贵参考。

3.5.2 CloudMatrix384 与 DeepSeek 模型的架构协同

本小节以 DeepSeek-R1 为代表性工作负载，分析华为 CloudMatrix384 的架构特性如何契合大规模 MoE 模型推理服务的需求。我们聚焦四个关键的协同维度：MoE 通信、内存可扩展性、缓存复用与量化支持。

MoE 通信协同：高效的分发与合并。DeepSeek-R1 采用 MoE 架构，在 token 分发与专家输出合并期间对 NPU 间通信提出很高要求。CloudMatrix384 高带宽、低时延的 UB 互连恰好契合这些需求。分发阶段，token 必须从路由器送往被选中的专家，跨度可达数百个 NPU；all-to-all 的 UB 拓扑确保以极小开销快速送达。类似地，合并阶段需要跨分布式计算单元以加权求和方式融合多个专家的输出。UB 平面的高带宽使专家输出得以高效汇集，优于网络性能可能严重拖累 MoE 推理吞吐的传统架构。

内存容量与管理：容纳大模型与 KV 缓存。DeepSeek-R1 参数量接近 671B，其权重与激活（包括注意力 KV 缓存）都需要庞大的内存资源。CloudMatrix384 提供总量巨大的 NPU 侧内存，可通过张量并行、流水线并行与专家并行相结合的方式分布式存储模型权重。除模型权重外，LLM 的注意力机制还会维持可观的 KV 缓存，在长上下文或高批次负载下尤甚。CloudMatrix384 充裕的内存规模能够支撑这些场景，但跨 NPU 高效划分与同步 KV 缓存依然必不可少。

上下文缓存复用：加速缓存访问。LLM 负载——尤其是多轮对话与长上下文应用——能从前缀缓存复用中显著获益，DeepSeek-AI 报告的缓存命中率超过 56%。在传统系统中，从片外 DRAM 乃至更慢的存储层检索历史 KV 缓存会引入显著时延，拖累推理性能。CloudMatrix384 让 NPU 经高带宽 UB 平面直接访问分离式的 CPU 侧 DRAM 池，从而化解这一瓶颈（§4.4.1）。该架构为远程 KV 缓存访问提供内存级的带宽与时延，因而能最大限度减少冗余 prefill 计算、显著降低首 token 时间（TTFT），并可高效扩展至长上下文负载而不耗尽有限的 NPU 内存。

面向效率的量化：INT8 支持。Ascend 910 对 INT8 计算的支持（如 §3.3.1 所述）为优化推理性能

DeepSeek 模型。将模型权重与激活从更高精度格式（如 FP16 或 BF16）量化为 INT8，可以显著降低模型的内存占用、减少计算开销，并减轻执行期间的内存带宽需求。这些收益能够转化为更高的吞吐量与更低的时延。

总而言之，CloudMatrix384 的架构——包括大规模 NPU 算力、充裕的内存容量、高带宽 UB 互连以及基于 DRAM 池化的缓存——与大规模 LLM 推理服务的需求高度契合。这些协同优势为后续小节提出的优化推理架构奠定了坚实基础。 4 在华为 CloudMatrix384 上进行 DeepSeek 推理服务 为了充分发挥 CloudMatrix384 的能力，我们提出 CloudMatrix-Infer，一套完整的 LLM 推理服务方案，为部署大规模 MoE（混合专家）模型确立了最佳实践。我们以 DeepSeek-R1 模型为代表性示例，阐述我们推荐的架构与技术，通过跨层优化在 CloudMatrix384 上实现高效 LLM 推理服务。Figure 8 概述了所提出的横跨 AI 软件栈多个层次的优化技术。

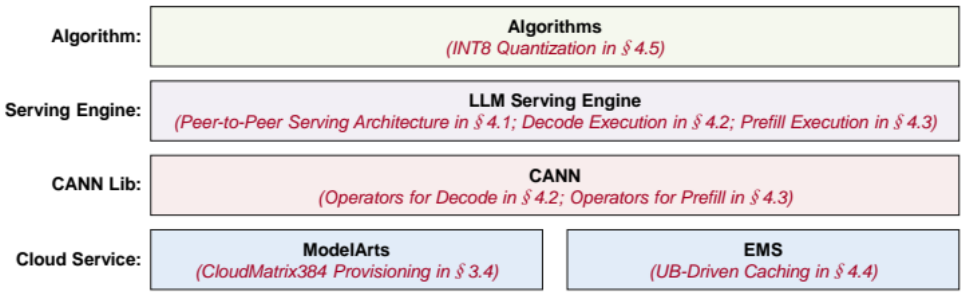


Fig. 8. 我们提出的各项优化技术在 AI 软件栈不同层次中的总览。

来源：p.17 C008（原文 Fig. 8）

在本节中，我们首先介绍一种新颖的*对等推理服务架构（peer-to-peer serving architecture）*，它基于 prefill-解码-缓存分离（PDC 分离），将 prefill（预填充）、解码与缓存三类职责解耦，并映射到经由高性能 UB 互连的专用 NPU 与 CPU 组（§4.1）。随后我们介绍*紧耦合解码优化*，将大规模专家并行（LEP）扩展到数百个 NPU 芯粒上以加速 MoE 推理（§4.2）。接着，我们描述*资源高效的 prefill 策略*，通过混合并行与流水线提升计算效率（§4.3）。我们进一步阐述*UB 驱动的分布式缓存机制*，统一跨节点的内存访问，实现对模型与历史 KV 缓存的低时延访问（§4.4）。最后，我们详述系统对 *INT8 量化*的支持，进一步提升端到端推理效率（§4.5）。

4.1 概览：采用 PDC 分离的对等推理服务架构

CloudMatrix-Infer 的架构设计以 *分离式*与 *对等通信*为原则，将 LLM 推理工作流分解为可独立扩展的组件，同时利用 CloudMatrix384 的高带宽互连实现高效协同。基于这些原则，我们提出一种独特的 *对等推理服务架构*，将系统划分为三个功能子系统，即 prefill（预填充）、解码与缓存（PDC），各子系统独立运行，并通过显式的 KV 缓存传输接口通信，如 Figure 9 所示。这种对等设计使各子系统能够基于

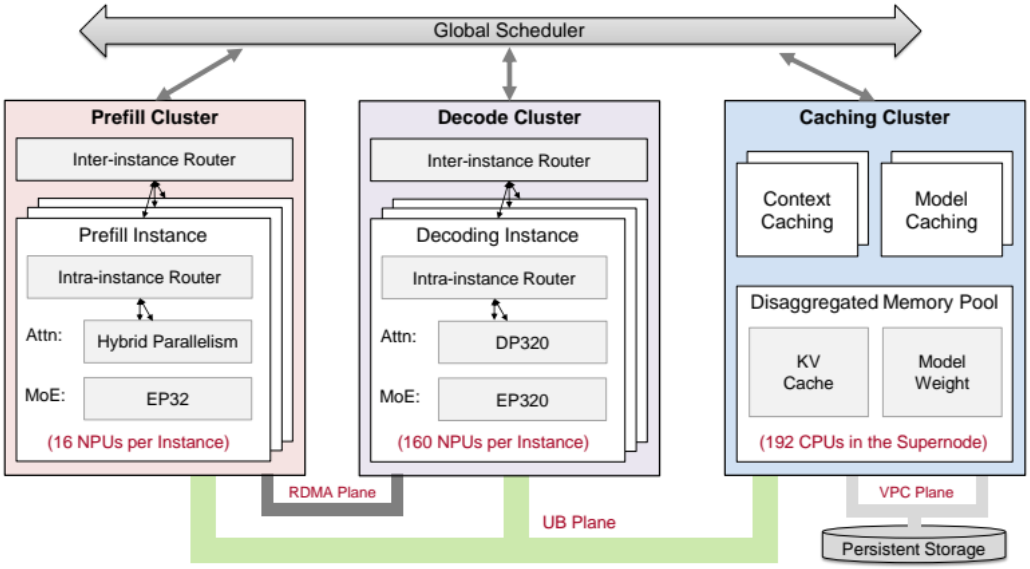


Fig. 9. CloudMatrix384 上采用 prefill-解码-缓存分离（PDC 分离）的对等推理服务架构，使所有 NPU 都能经由超高带宽 UB 网络统一访问由分离式内存池支撑的共享缓存集群。

来源：p.19 C009（原文 Fig. 9）

……负载需求，从而最大化资源利用率与端到端性能。这些子系统通过 CloudMatrix384 的高带宽网络互连，构成一条紧密集成的推理流水线：• *Prefill 集群：*一组专门处理输入 prompt 的 NPU，输入 prompt 包含用户 query 或上下文中的全部 token，用于生成首个输出 token 并构建初始 KV 缓存。• *解码（Decode）集群：*另一组 NPU，负责以自回归方式生成后续 token，在此过程中消费并更新 KV 缓存，直到产生序列结束（end-of-sequence）token 或达到输出长度上限。• *缓存（Caching）集群：*构建在分离式内存池之上、由 UB 互连的缓存层，提供（i）*上下文缓存（context caching）*，通过 KV 缓存复用加速 prefill；（ii）*模型缓存（model caching）*，加速模型分块加载并降低冷启动时延。

为了更好地理解我们设计的动机与有效性，不妨将其与现有 LLM 推理服务系统中占主导地位的 *KVCache 中心化（KVCache-centric）*架构 [41, 48] 进行对比。

KVCache 中心化 vs. 对等推理服务架构：NVIDIA Dynamo [41] 与 Mooncake [48] 等现有 LLM 推理服务系统遵循 *KVCache 中心化*设计，请求调度与 KV 缓存局部性紧密耦合。在这类系统中，请求通常被路由到已持有前次交互对应 KV 缓存的特定计算节点。这种缓存感知调度对于缓解远程内存访问的显著性能损失至关重要：节点内内存访问（例如经由 PCIe，约 256 GB/s）远超节点间带宽（通常约 25 GB/s，即 200 Gbps）。因此，远程加载 KV 缓存往往会带来可观的时延。然而，这种设计引入了不小

的调度复杂度，并有损害负载均衡的风险，在动态负载下尤甚。此外，该设计还限制了全局资源效率：解码节点上的 DRAM 通常彼此割裂且利用率不足，难以为共享缓存容量做出有效贡献。

CloudMatrix-Infer 中的*对等推理服务架构*充分利用了 CloudMatrix384 超高带宽的 UB 互连，使构建在分离式内存池之上的分布式缓存集群（Section 4.4）可以被统一访问。关键在于，所有 NPU 无论承担 prefill 还是解码任务，都可以直接访问这个横跨 prefill 节点与解码节点的共享分离式内存池。这种完全对等的设计有效地*拉平了内存层次结构（flattens the memory hierarchy）*，弥合了本地访问与远程访问时延之间的传统鸿沟。

将请求调度与 KV 缓存放置解耦带来若干关键优势。其一，实现了轻量级的无状态调度，推理请求可以被派发到任何可用的 NPU 实例，而不受数据局部性约束，显著改善了全系统负载均衡与 NPU 利用率。其二，免除了复杂的亲和性感知调度机制，降低了架构复杂度并减轻了系统维护负担。其三，通过将 prefill 节点与解码节点的 DRAM 资源池化，系统形成一个统一且富有弹性的缓存基底，提升内存利用率、提高缓存命中率，并在倾斜或突发负载下具备更强的韧性。

Prefill 与解码的部署方式。与先前工作 [41, 47, 48, 57] 一致，CloudMatrix-Infer 采取将 prefill 与解码两个阶段分离到不同 NPU 组的策略。通过解耦这两个性能瓶颈特征各异的阶段，CloudMatrix-Infer 得以按阶段特性进行硬件分配与并行执行，并随动态负载特征独立扩展。

每个 prefill 实例在 CloudMatrix384 上配置 16 颗昇腾 910（Ascend 910）NPU（32 个芯粒），以 32 路专家并行（EP32）运行。该专家配置在每个

rank 中包含 10 个专家：一个共享专家、八个路由专家，以及一个用于支持专家并行负载均衡（EPLB）的冗余路由专家。为进一步提升效率，我们在多头潜在注意力（MLA）计算中采用混合并行策略，并应用基于微批次的流水线来掩盖通信开销（§4.3）。

每个解码实例则分配规模大得多的 NPU 组，通常为 160 颗昇腾 910 NPU（320 个芯粒），以满足自回归生成对高吞吐与低时延的要求。该配置对应 MoE 层的 320 路专家并行（EP320）。每个 rank 承载一个专家，整体配置包括 32 个共享专家、256 个互不相同的路由专家，以及 32 个便于 EPLB 的冗余路由专家。为进一步加速解码，我们引入了优化的昇腾原生算子、流水线化解码策略以及多 token 预测（MTP）支持，详见 §4.2。

面向异步真实负载的动态调整。在真实在线服务场景中，分离式的 PDC 服务架构支持根据流入负载的统计特征，动态、细粒度地调整 prefill、解码与缓存节点的数量。例如，输入 prompt 较长的请求会提高对 prefill 节点的相对需求，而生成较长输出的负载则需要更多解码容量。这些比例并非固定不变，而是随时间自适应调整，以最大化效率并维持时延服务级目标（SLO）。

此外，用户会话的到达与离开都是异步的，各自具有不同的起始时间、prompt 长度与生成时长。为应对这种高度动态且不可预测的负载模式，CloudMatrix-Infer 的职责是通过批处理与调度机制强制实现伪同步执行。具体而言，它在 token 边界处对齐请求，使多个会话可以被协同调度、并发处理。这种批处理策略摊薄了计算成本、提升了吞吐量，即使在完全异步的请求到达模式下也能确保较高的资源利用率。

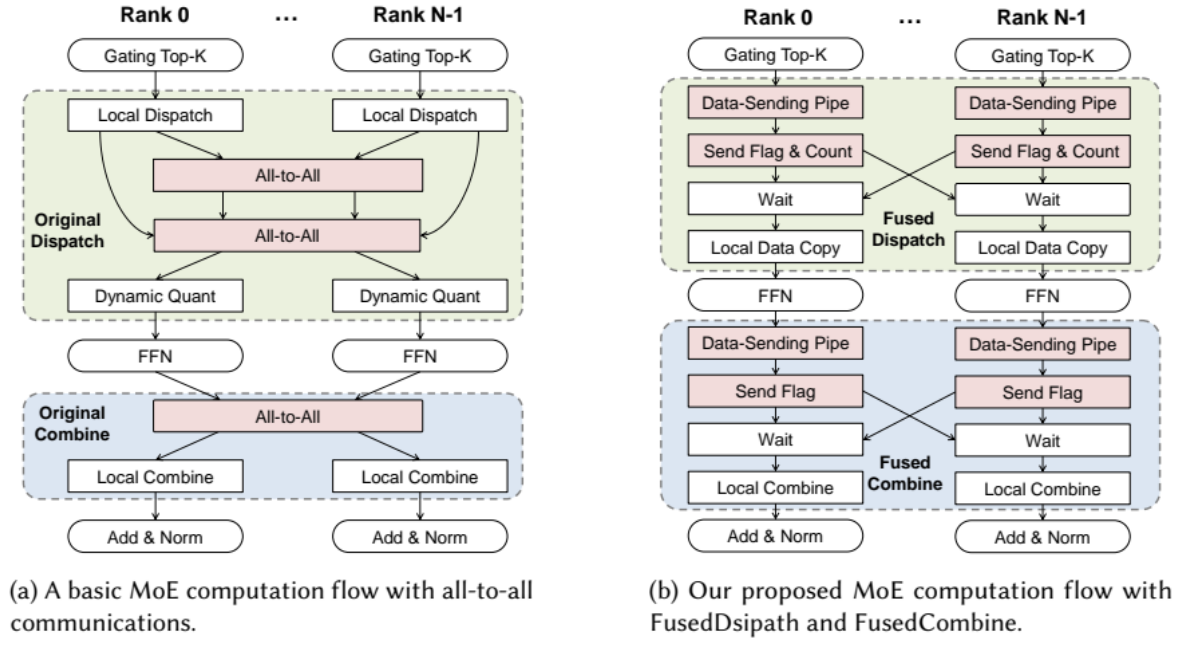
4.2 紧耦合解码与大规模专家并行

本节概述 CloudMatrix-Infer 中借助 CloudMatrix384 紧耦合 UB 平面实现的解码阶段优化。要最小化 MoE 模型的每 token 输出时间（TPOT）时延，需要细粒度的专家并行（EP），将每个专家部署在专属的 NPU 芯粒上。DeepSeek-R1 模型部署了 256 个路由专家，使大规模专家并行（LEP）成为核心需求。然而，实现 LEP 并非易事：token 处理存在顺序依赖，且协调数百个 NPU 芯粒会带来可观的通信开销。

为应对这些挑战，我们提出一套面向 CloudMatrix384 的硬件感知优化技术。首先，我们介绍融合通信算子设计，利用 UB 平面实现低时延、高吞吐的 MoE 执行（§4.2.1）。接着，我们详述面向昇腾 910 的定制 MLA 实现（§4.2.2），并描述一种基于微批次的解码流水线，通过重叠两条执行流来掩盖时延（§4.2.3）。最后，我们说明 CloudMatrix-Infer 如何支持多 token 预测（MTP）——DeepSeek-R1 借助该特性提升解码吞吐量（§4.2.4）。

4.2.1 面向 LEP 的融合通信算子

Figure 10a 展示了基本的 MoE 计算流程。在门控机制为每个 token 选出 Top-K（DeepSeek-R1 中 K = 8）个激活专家后，前馈网络（FFN）阶段之前需要两步 all-to-all 通信。第一次 all-to-all 通信在所有 NPU 间交换路由元数据，例如 token 到专家的分配关系。第二次 all-to-all 通信交换实际的 token 数据，通常为每 token 一个 7,168 维隐藏状态向量。该数据最初以 BF16 格式存储，在各 NPU 上被量化为 INT8 以降低通信与计算开销，随后交由其所属的 FFN 处理。FFN 计算完成后，第三次 all-to-all 通信将专家输出送回各自的源 rank，各 NPU 在此执行最终的 token 合并步骤以重构输出。然而，这一基本的 MoE 实现存在若干低效之处：



(a) A basic MoE computation flow with all-to-all communications.

(b) Our proposed MoE computation flow with FusedDsipath and FusedCombine.

Fig. 10. 采用 all-to-all 通信的基本 MoE（混合专家）计算流程与我们提出的采用融合通信算子的 MoE 计算流程的对比。

来源：p.21 C010（原文 Fig. 10）

(1) *通信开销：*三次 all-to-all 通信会引入可观的时延，而庞大的通信域（数百个 NPU）又进一步加剧了这一问题。

(2) *动态形状：*all-to-all 通信的数据形状是动态变化的，因为每个解码迭代中分配给各专家的 token 数量不同。这种动态性要求动态内存分配和频繁的 CPU-NPU 同步，从而降低执行效率。

(3) *顺序依赖：*MoE 计算的串行执行特性在步骤之间制造了依赖关系，降低了资源利用率与吞吐量。

为消除这些低效问题，我们开发了 FusedDispatch 与 FusedCombine（融合分发/融合合并）这两个通信与计算一体化的融合算子，专门为在 CloudMatrix384 上取得最优解码性能而设计。第一，为降低 all-to-all 通信开销，这两个融合算子用收发（send-receive）原语取代了所有 all-to-all 通信；我们还利用 UB 平面中 NPU 间的直接写入来降低通信时延，并将分发（dispatch）阶段中的量化操作前移到 NPU 间通信之前，以减小消息尺寸。第二，为消除动态形状带来的开销，我们为算子预先分配全部所需内存空间，从而支持静态图执行。第三，为降低串行执行的开销，算子内部的通信与计算步骤也被组织成流水线，提升资源利用率与吞吐量。这些优化详述如下。

1跨 NPU 的 AIV 直连通信：NPU 之间常规的 all-to-all 通信通常依赖 SDMA（系统 DMA）引擎之类的通信固件来传输数据（Figure 11 中红线）。然而，SDMA 会引入可观的启动开销，在超低时延场景（尤其是解码期间）成为关键性能瓶颈。为突破该瓶颈，我们设计了一种新的通信机制，称为 *AIV-Direct*。AIV-Direct 使 AI 向量核（AIV）能够经由 UB 互连直接将数据写入远程 NPU 的内存，完全绕开易引入时延的 SDMA 路径（Figure 11 中蓝线）。通过消除 SDMA 的启动开销，AIV-Direct 为对等通信提供了一条快速轻量的通路，大幅降低了传输发起时延，加速了 NPU 间数据交换，显著提升了解码等时延敏感操作的性能。提前量化（Early Quantization）：2 在原始 MoE 计算流程中，如 Figure 10a 所示，token 分发阶段传输的是 BF16 token 数据，通信量很大。为缓解这一问题，我们在 FusedDispatch 内部发送 token 数据之前执行 INT8 量化，即引入*提前量化（early quantization）*。具体而言，我们不再发送 BF16 数据，而是传输 INT8 量化后的数据及其缩放因子，从而减少数据交换阶段的通信载荷。对于 7,168 维的 token 数据，INT8 表示每 token 需要 7 KB；缩放因子占用 4 字节（INT32），为对齐起见我们分配 512 B。因此每 token 的传输消息大小为 7.5 KB。该优化在带宽消耗最大的阶段大幅削减了通信开销。

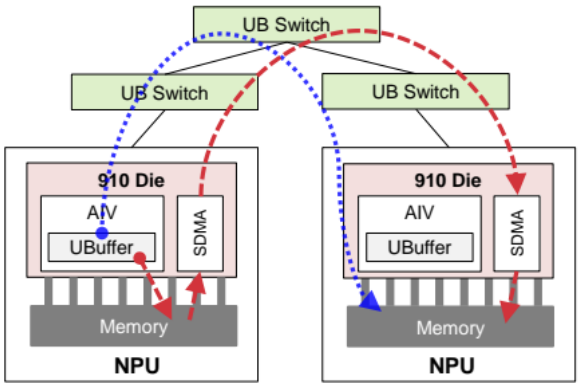


Fig. 11. NPU 间基于 SDMA（系统 DMA）的通信与 AIV 直连通信的对比。红线与蓝线分别表示使用 SDMA 与 AIV 直连的数据传输路径。

来源：p.22 C011（原文 Fig. 11）

3基于共享内存预分配的静态执行：为避免动态内存分配及其伴随的 CPU-NPU 同步开销，我们在每个 NPU rank 中静态预分配共享内存缓冲区，用于存放 MoE 层中来自其他所有 rank 的数据。所需缓冲区大小为：

$$\text{buffer_size} = \text{rank_num} \times \text{max_tokens} \times \text{msg_size} \tag{1}$$

通信缓冲区预分配大小公式（符号保持原样，已对照原 PDF 裁片核验。）

其中

$$\text{max_tokens} = \text{local_batch} \times \min(\text{topK}, \text{experts_per_die}) \tag{2}$$

单个对端最坏情况下 token 数上限（符号保持原样，已对照原 PDF 裁片核验。）

max_tokens 是一个 NPU 在最坏情况下可能向单个对端发送的 token 数，msg_size 是每 token 的消息长度（INT8 量化后，token 分发为 7.5 KB，token 合并为 14 KB）。

凭借这块预分配空间，FusedDispatch 与 FusedCombine 都通过 AIV 直连通信将数据直接写入目标 NPU 的内存缓冲区，避免了中间的本地拷贝以及随后的远程读取，从而降低内存流量与同步时延。

由于 FusedDispatch 与 FusedCombine 背靠背执行，共享同一缓冲区会产生竞争：较快的 NPU 可能启动 FusedCombine，并在对端尚未消费完先前 FusedDispatch 载荷时覆写其对端缓冲区，导致数据损坏。我们通过*双缓冲（double buffering）*消除 FusedDispatch 与 FusedCombine 之间的这一冒险：为二者分别保留独立缓冲区，确保写者始终有一个空闲缓冲区可用，而另一个缓冲区正被读取。

预分配带来的内存开销并不大。在我们的实验配置中，每个芯粒处理本地批次最多 96 个 token，且最多承载两个专家，即 max_tokens = 96 × min(8, 1) = 96。在由 320 个 rank 组成的通信域中，分发缓冲区占用 320 × 96 × 7.5 KB ≈ 225 MB，合并缓冲区占用 320 × 96 × 14 KB ≈ 420 MB。两个缓冲区合计每芯粒仅消耗约 645 MB 内存。数据发送流水线：4 远程数据写入需要计算对端 NPU 预分配内存缓冲区内的目标偏移量。但如果串行地执行该计算与传输，执行将会停顿。为避免这一点，我们在每个融合算子内部设计了数据发送流水线（如 Figure 12 所示），将以下三个阶段流水线化：(1) 将下一个 token 拷贝进本地 UBuffer；(2) 计算远程缓冲区偏移量，并在启用时施加 INT8 量化；(3) 发起对对端 NPU 内存的 AIV-Direct 写入。token 以单 token 微批次的形式流经该流水线：当某个微批次的阶段 3 在传输数据时，后续微批次的阶段 1 和阶段 2 并行执行。这种重叠同时掩盖了计算与通信时延，使 token 分发得以持续高效地进行。

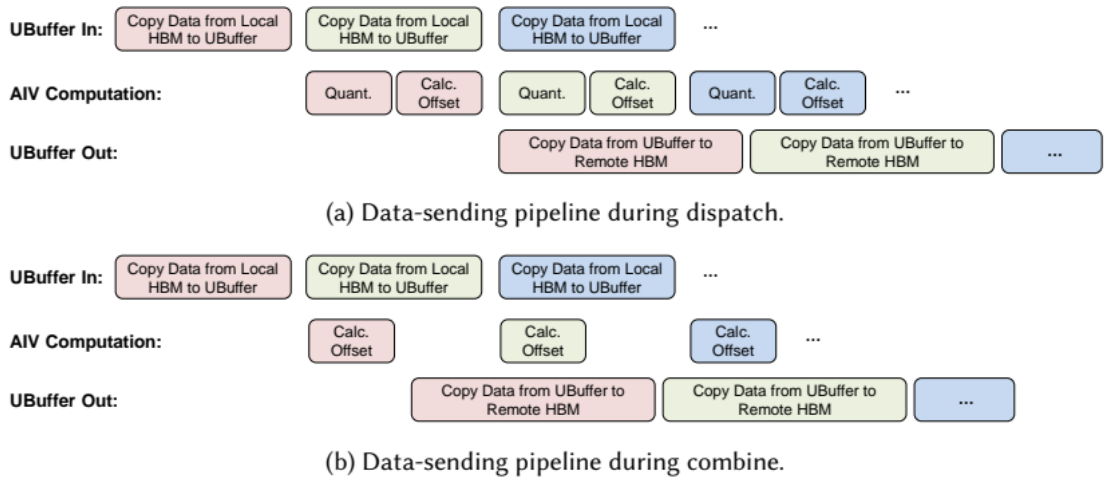


Fig. 12. token 分发与 token 合并的数据发送流水线：前者采用动态量化，后者传输未量化数据。

来源：p.23 C012（原文 Fig. 12）

通过综合运用 AIV 直连通信、提前量化、预分配的双缓冲内存以及数据发送流水线等技术，FusedDispatch 与 FusedCombine

这两个算子相比基础实现显著降低了解码期间 MoE 层的时延。这两个融合算子的工作流程如 Figure 10b 所示。

FusedDispatch 算子的执行包含三个主要步骤。第一步是流水线化的 token 发送阶段（Opt. 4）。每个 rank 遍历分配给远程专家的 token：对每个 token，分发 AIV 核先将相关 token 数据从内存载入本地 UBuffer，随后将其量化为 INT8 格式（Opt. 2）并附加相应的缩放因子；同时为每条 token 数据附带路由元数据，包括源 rank ID、批次槽位 ID 和键偏移量。系统随后为每个专家 ID 确定目标 rank，并经由 AIV 直连将数据包写入对端预分配的共享内存缓冲区（Opt. 1 和 3）。第二步，一旦所有数据包都已发出，便由一个屏障（barrier）确保所有 token 数据写入完成后才发送标志位：分发核并行计算每个专家的 token 数量，在核间同步后，再使用 AIV 直连向相应对端发出完成标志与 token 计数（Opt. 1 和 3）。最后一步是协调与输出组装：每个 rank 轮询远程 rank 写入的标志位，等待所有标志位均被置为'1'；随后读取相应的 token 计数以计算输出偏移量；最后，所有分发核并行工作，将共享内存中收到的 token 数据、量化缩放因子以及每个专家的 token 计数组装进连续的输出缓冲区，为后续 FFN 计算阶段做好准备。

FusedCombine 的工作流程同样由三个主要步骤构成。第一步是流水线化的数据发送阶段（Opt. 4）：每个合并 AIV 核循环遍历其负责的对端 rank，读取每个对端相应的接收计数，并将对应的 FFN 结果数据拷贝进本地 UBuffer；它利用 token 的源元数据——具体为源 rank ID、批次槽位 ID 和键偏移量——计算对端上的目的地址，随后通过 AIV 直连将 token 数据传回源 rank 上的预分配缓冲区（Opt. 1 和 3）。第二步，再次利用每个 token 的元数据计算其标志位更新的目标地址：合并 AIV 核经 AIV 直连发起一次原子加（atomic-add）操作，递增对端相应的标志位，表明一份贡献已送达（Opt. 1 和 3）。在最后一步，每个核等待其负责批次的标志位全部置为'1'，表明该 token 的所有专家输出均已到达；随后合并核从共享内存中收集专家 FFN 输出，并从内存中取出相应的

缩放因子，执行逐元素缩放并对结果求和。合并后的专家输出再加上共享 FFN 的输出，得到每个 token 的最终结果。

4.2.2 MLA 优化

DeepSeek 提出的多头潜在注意力（MLA）利用低秩压缩缩减 KV 缓存的空间占用，并引入权重吸收技术以降低计算开销。虽然 MLA 可以部署在 CloudMatrix384 上，但将 DeepSeek 的算子直接迁移到 Ascend 910 NPU 会暴露出若干性能瓶颈：

(1) *细粒度算子的启动开销：*MLA 引入了大量细粒度操作，如 RMSNorm、线性投影和 RoPE 编码，它们通常被实现为独立的 NPU 算子。每次算子调用都会带来不可忽略的启动时延，来源于 CPU 侧派发、参数加载、指令调度与切分（tiling）配置。虽然将这些算子捕获进图中可以通过把多个操作成组来摊薄 CPU 派发开销，却无法消除 NPU 上每个算子的启动成本。因此，这些细小内核启动的不断累积在 MLA 执行路径中引入了可观的时延。

(2) *KV 缓存格式转换开销：*为支持高性能矩阵计算，昇腾 910 NPU 的 AI Cube 核（AIC）的 L1 Cache 以 NZ 格式存储数据时效率最优（NZ 是一种行主序与列主序混合的专门布局，形成 N 形与 Z 形相结合的遍历路径）。然而，KV 缓存通常以标准 N 维（ND）格式存放在 NPU 内存中。因此，算子内部往往需要先将 KV 缓存数据显式转换为 NZ 格式，AIC 才能执行矩阵计算。这种显式格式转换消耗内存带宽、影响访问效率，从而减少了可用于计算的有效内存带宽。

(3) *多 token 预测（MTP）带来的负载不均衡：*启用 MTP 后，解码阶段需要验证上一步预测出的多个 token，导致同一批次内不同 query 的有效序列长度各不相同（详见 §4.2.4）。面向注意力算子的原有切分策略通常假定 BNSD（Batch、Num-heads、Sequence-length、Head-dimension）内存布局，可能造成显著的负载不均衡。具体而言，不启用 MTP 时，一个解码步中所有 query 的序列长度 S 通常为 1，基于 B 轴与 N 轴的切分策略可以据此创建大小相等的计算任务（因为每个任务的 S 与 D 均为常量），从而保证负载均衡；而 MTP 生效时，序列长度 S 会因 query 而异。在这种情况下若仍沿用 B 轴与 N 轴切分，将在 NPU 各核之间造成显著的负载差异，拉长 MLA 的整体计算时间。

为克服上述局限并充分发掘昇腾 NPU 的能力，我们提出以下对 NPU 友好的优化：

融合算子：MLAProlog 与融合注意力（FA）。为大幅降低 MLA 计算路径中大量小算子带来的启动开销，我们采用激进的算子融合，概念性示意如 Figure 13 所示。

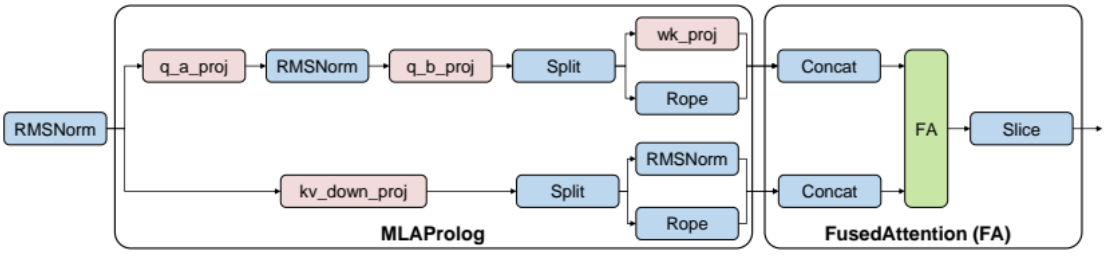


Fig. 13. MLAProlog 与 FA 算子，是我们 MLA（多头潜在注意力）优化的关键组件。

来源：p.24 C013（原文 Fig. 13）

首先，将 RMSNorm、Q/K/V 投影和 RoPE 等多个注意力前（pre-attention）操作合并为一个复合算子，称为 MLAProlog。这一融合把算子启动成本从多个独立算子的开销降到仅一次。此外，MLAProlog 在设计上具备内部微并行性，将工作负载划分为多个子任务，在 AIC 与 AIV 单元之间以流水线方式执行。这种细粒度的 AIC-AIV 并行，使不同子任务在这些异构核上的计算时间能够相互掩盖，进一步最小化融合算子的执行时间。

其次，作为 MLAProlog 的补充，我们开发了融合注意力（FA）算子，将 Concat、FlashAttention 与相邻的数据整形操作整合在一起，例如注意力前的准备操作（用于生成 Q、K、V）以及注意力后的 Slice（用于提取相关输出）。这进一步减少了内核启动次数，并改善了整个注意力计算路径的数据局部性。

NZ 格式的 KV 缓存。为消除张量格式转换开销，我们在 NPU 内存中原生以 NZ 格式存储 KV 缓存。在 MLA 计算过程中，计算得到的 KV 张量直接以该 NZ 格式追加进 KV 缓存。在解码阶段，随着新 KV 张量逐 token 生成，可按 NZ 格式规则高效写入 NPU 内存。昇腾 NPU 提供的数据搬移接口能够在内存写入过程中即时完成格式转换。这种*带格式转换的写入（write-with-format-conversion）*能力避免了对 KV 缓存执行显式、独立的 ND 到 NZ 数据变换步骤，从而提升了 NPU 有效内存带宽利用率。

基于 BSND 布局的 MTP 感知切分。为了在 MTP 下恢复负载均衡，我们将内存布局从 BNSD 调整为 BSND，并沿随 query 变化的批次（B）轴与序列（S）轴采用动态切分策略。由于 N（头数）与 D（头维度）在这些操作中保持相对稳定，这保证了各 AIC 核之间任务大小更加均匀，减少了由拖后计算任务造成的尾时延。

算子融合、原生 NZ 存储与自适应切分这三种策略相互配合，最大化了 CloudMatrix384 上基于 MLA 的推理性能，为 DeepSeek 模型带来时延与吞吐量的大幅提升。

4.2.3 基于微批次的解码流水线

融合通信算子（§4.2.1）虽能缓解部分开销，但专家并行通信引入的时延仍是解码阶段的重要因素。为进一步提升效率，受 DeepSeek 微批次流水线策略 [56] 启发，我们为 CloudMatrix384 设计了定制的 *基于微批次的解码流水线*，通过两条流之间细粒度的时延重叠，最大化资源利用率并降低执行时延。

由于昇腾 NPU 的独特特性以及我们针对 MoE 模型的特定并行部署方式，我们所提出的资源划分与流水线策略与 DeepSeek 的方法有所不同。DeepSeek 在 NVIDIA H800 上的部署如 Figure 14a 所示，每个 GPU 上共置三个专家（一个共享专家和两个路由专家）；而我们在 CloudMatrix384 上的部署采用很大的专家并行度（EP320），通常每个 NPU 芯粒仅承载一个专家，以获得低解码时延。由于没有共享专家计算可依托，仅靠 ATTN-0 的计算时延不足以完全掩盖 MoE 分发时延。这就需要一种不同的负载均衡流水线策略。

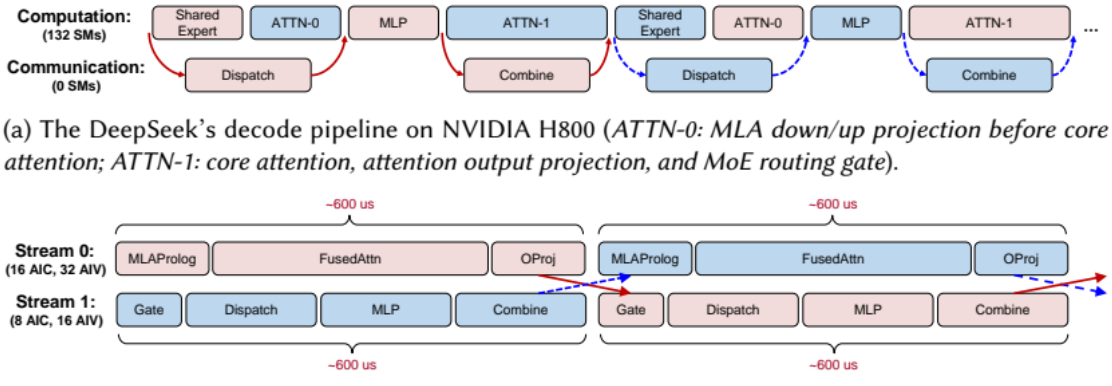


Fig. 14. 解码流水线对比：(a) DeepSeek 在 H800 上的方案与 (b) 我们提出的 CloudMatrix384 流水线。交替的颜色表示两个交错执行的微批次。

来源：p.26 C014（原文 Fig. 14）

为了在这些条件下实现高效的时延重叠，我们在 CloudMatrix384 上实现了带有 *AIC 与 AIV 非对称划分*的微批次流水线，如 Figure 14b 所示。该流水线由两条交错的执行流组成，各自负责解码过程的不同部分，并被分配不同的计算资源：• *流 0（注意力路径）：*执行 MLAProlog、FusedAttention 与 O_PROJ。这些算子计算密集或访存密集，因此被分配更多 NPU 资源——16 个 AIC 和 32 个 AIV。在典型解码条件（4K 序列、batch size 96、启用 MTP）下，该流的每微批次时延为 600 μs。• *流 1（MoE 路径）：*处理 MoE 序列：Gate、Dispatch、MLP 与 Combine。由于同时包含计算与通信阶段，该流仅分配 8 个 AIC 和 16 个 AIV，是流 0 资源的一半；但由于计算负载较低而通信时延较高，其时延仍与流 0 相当（600 μs）。

这种非对称分配确保流 0 与流 1 执行时每层时延接近，从而使两个交错的微批次能够完美重叠。如 Figure 14b 中交替的颜色所示，当流 0 处理一个微批次的注意力计算时，流 1 同时对另一个微批次执行 MoE 计算与通信。

为适应不断变化的运行时条件（例如 KV 缓存长度的变化），两条流的计算资源分配可以自适应调整。这种弹性确保时延均衡得以保持，使系统在多样负载下持续保持性能。

4.2.4 多 token 预测（MTP）支持

多 token 预测（MTP）是 DeepSeek-R1 采用的一种投机解码技术：每个解码步预测 k 个 token，并在后续步骤中对这些预测进行验证。通过每次解码生成多个 token，MTP 可显著提升吞吐量。然而，在现有推理框架中启用 MTP 往往因 CPU 与 NPU 之间的紧同步而带来严重低效，导致流水线中断、性能下降。我们将其称为 *流水线断裂问题*。

如 Figure 15b（朴素的 MTP 流水线）所示，MTP 通常在每个解码步触发 k + 1 个计算图，其中 k 个用于投机（speculative）模块，一个用于最终验证。每次计算图派发会引入 0.6–0.8 ms 的启动时延。这一开销——尤其是在由 CPU 居中协调的情况下——

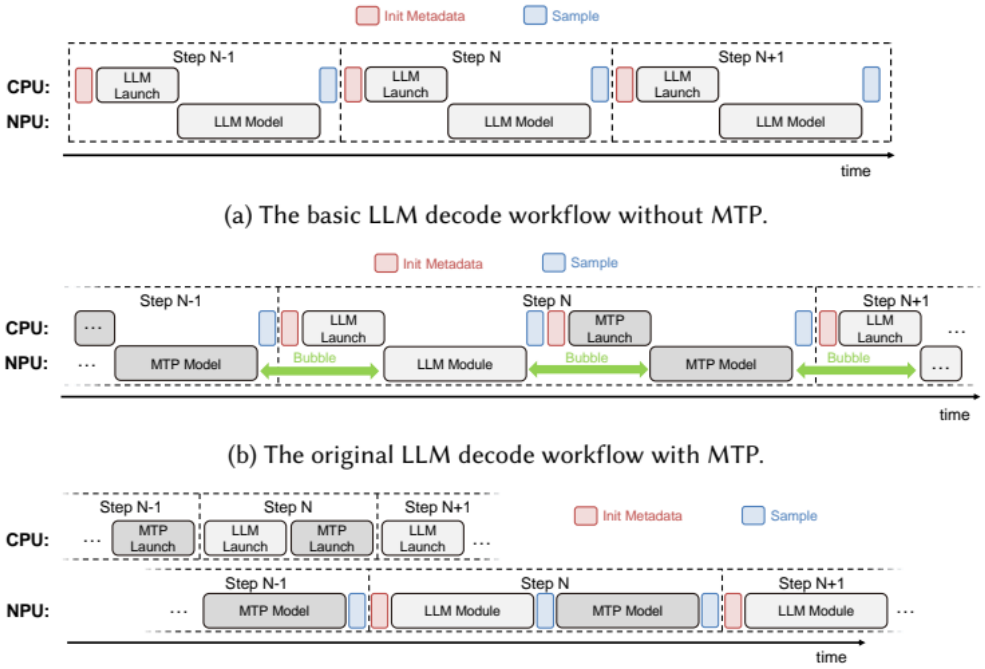


Fig. 15. Ascend NPU 上的流水线化多 token 预测（MTP）优化。

来源：p.27 C015（原文 Fig. 15）

会导致 NPU 上出现空闲气泡，削弱 MTP 的收益。我们识别出造成这些障碍的两个主要来源：• *动态元数据初始化需要 CPU 介入：*MTP 模块与主 LLM 都依赖诸如当前序列长度之类的元数据，这些元数据在解码过程中动态变化，且只有在前一模块执行完成后才能最终确定。例如，MTP 模块需要用到上一次 LLM 验证之后才确定的序列长度。如 Figure 15b 所示，CPU 在派发每个计算图之前都要初始化并传输该元数据，导致频繁的 CPU-NPU 同步屏障。• *CPU 介入的采样干扰 NPU 执行：*在 MTP 模块与主 LLM 生成 token 分布之后，需要进行采样以选出实际的 token。该过程混合了 CPU 流程与离散的 NPU 操作，频繁的 CPU-NPU 交互带来了主机与设备之间数据拷贝的开销。更关键的是，由于每个后续计算图都依赖前一个计算图的采样输出，这引入了串行化，使 NPU 无法连续执行。

为突破这些瓶颈，我们提出一种流水线化 MTP 执行技术（Figure 15c），消除上述 CPU 依赖，实现高效的计算图执行：

聚合元数据初始化。我们不再为 k + 1 个计算图分别执行元数据设置，而是在解码步开始时预先计算并批量准备全部元数据张量。这些直接存储在 NPU 内存中的张量包括每个 MTP 模块的增量序列长度，以及验证图的元数据块。这消除了 CPU 的反复介入，使 NPU 上能够无缝执行感知元数据的计算图。

免 CPU 的 NPU 内采样。为消除基于 CPU 的采样频繁造成的 NPU 执行停顿，我们将整个采样过程迁移到 NPU 上。该策略将所需的各种采样操作——如 token 概率排序、累加和计算以及候选过滤——实现为一串 NPU 算子。此外，为尽量减少分发大量 NPU 采样算子带来的启动开销，这些算子被融合进 MTP 与 LLM 验证计算图中。通过让采样完全在设备内完成，我们避免了 MTP 各阶段与 LLM 验证阶段之间的执行停顿，使计算图无需主机干预即可背靠背连续执行。

这些增强措施相辅相成，消除了朴素 MTP 实现中因 CPU-NPU 协同而频繁出现的流水线中断。当 NPU 执行某一个计算图时，CPU 并发调度下一个计算图，从而维持持续的并行度和不间断的 NPU 执行。由此在 NPU 上实现无缝的操作流，最大化其利用率，并充分释放 MTP 在时延上的潜在收益。

4.3 基于混合并行与微批次的资源高效 prefill

prefill 阶段负责处理输入提示词并生成初始 KV 缓存，对首 token 时间（TTFT）与系统吞吐量影响重大。鉴于该阶段通常计算密集，在 prefill 期间达成高 NPU 利用率至关重要。然而，这一阶段常面临诸多挑战，例如输入序列长度异构导致的负载不均衡以及通信开销，在 MoE 模型这类复杂架构中尤为突出。为解决这些问题并在 CloudMatrix384 上最大化效率，我们在 CloudMatrix-Infer 中提出三项关键优化。首先，提出面向 MLA 计算的 *分阶段混合并行*方案，克服传统数据并行的固有低效（§4.3.1）。其次，提出 *基于微批次的 prefill 流水线*，利用 Ascend 910 NPU 异构的计算与通信单元最大化时延重叠并减少争用（§4.3.2）。最后，介绍 prefill 与解码阶段之间的传输优化，以最小化对解码的干扰（§4.3.3）。

4.3.1 面向 MLA 计算的混合并行

LLM 的 prefill 构成显著的计算瓶颈。尽管 CloudMatrix384 提供了充裕的算力与高带宽互连，我们观察到，DeepSeek 在 GPU 部署中最初用于 MLA 计算的纯数据并行（DP）方式（§3.5.1）

导致 Ascend NPU 上的负载均衡与资源利用率欠佳。这种低效主要源于两方面原因：

(1) *序列长度偏斜：*实践中，到来的请求往往具有不同的输入序列长度。在典型的 32 路 DP 配置下，分到较短序列的 NPU 会更早完成工作，随后在等待批次中最长序列处理完毕期间处于空闲，造成计算周期浪费。

(2) *并发不足：*若在途请求数少于 DP 度（例如 DP32 下不足 32 个请求），部分 DP 分片将无任务可执行。若延迟处理以凑满 32 个请求的完整批次，会增大 TTFT；若以部分批次运行，又会造成 NPU 资源利用不足。

为缓解上述低效问题，我们提出一种针对 prefill 阶段 MLA 计算优化的*分阶段混合并行*策略，图 16a 与图 16b 将其与基本 DP 进行了直观对比。我们将 MLA 分解为三个阶段，并对每个阶段采用不同的并行方案。

第一阶段（包括层输入处理与 down_proj 算子）和第三阶段（包括 o_proj 算子）所涉及的计算，其并行化策略本质上并不依赖于 token 在序列中的位置。对于这两个阶段，我们采用*序列并行（SP）与序列打包（sequence packing）相结合*的方式，取代纯 DP。该方法将多个请求的 prompt 序列拼接起来，再把打包后的超序列切分成段分布到各 SP rank 上。这样，不同长度请求的 token 便能近似均匀地分布到各 NPU 芯粒上，无论单个请求长度如何，都能实现有效的负载均衡。

第二阶段包括 q_up_proj、kv_up_proj 以及核心的 FlashAttention 机制，其注意力计算关键性地依赖于 token 位置。对该阶段，我们采用张量并行（TP），以确保计算负载在各 NPU 芯粒间均衡分布。在我们的 prefill 实现中，MLA 通常不做部分权重矩阵吸收（absorption），以提升原始计算效率，从而可将其有效地当作标准的 128 头多头注意力（MHA）运算来处理。鉴于 MHA 计算对每个注意力头相互独立，我们通过将这些注意力头均匀分布到各 NPU 芯粒来实施 TP。

在阶段之间切换不同的并行策略需要重新分布数据。我们在阶段 1 与阶段 2 之间插入一次 All-Gather，在阶段 2 与阶段 3 之间插入一次 All-to-All，以在各 rank 间正确地重新分片并分发激活数据。

图 17 给出了这种混合并行数据流的一个示例：四个长度不同的输入（Input 0、Input 1、Input 2、Input 3）在四个 NPU rank 上处理。起初在阶段 1，来自这些输入的 token 经打包后以 SP 方式分布。每个 rank 处理打包序列中的一段连续片段，确保所有 rank 分到大致相等数量的 token，

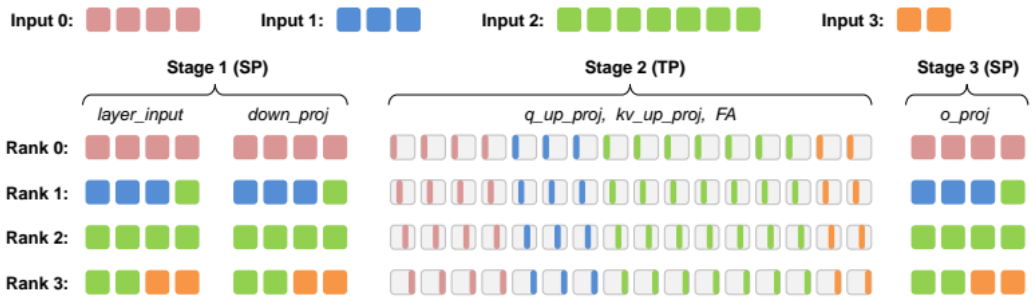
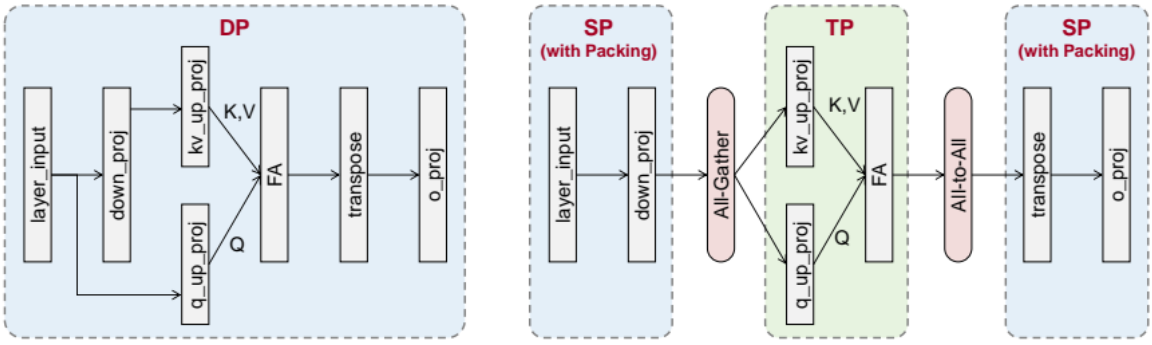


Fig. 17. prefill 中 MLA 计算的分阶段混合并行（SP-TP-SP）数据流示意图。

来源：p.29 C017（原文 Fig. 17）

从而尽管各原始查询长度不同，仍能均衡负载。进入阶段 2，先执行一次 All-Gather，再为 TP 重新分布数据：此时每个 rank 处理来自全部四个输入所有 token 的一个分片（例如注意力头的一个子集）。图中该阶段的彩色块表明，每个 All-to-All rank 此时负责每个输入的一部分。最后，经过一次从 TP 阶段收集结果的算子后，阶段 3 以与阶段 1 类似的方式、再次按 SP 组织的数据执行计算。该示例凸显了混合方法如何在 MLA 计算全程维持负载均衡。

与常规 DP 策略（图 16a）相比，这种混合并行引入了上述两步额外的集合通信，但其开销经过了仔细控制：All-Gather 在一次降维步骤（由 down_proj 隐含）之后执行，因而作用于可能更小的张量；All-to-All 集合通信主要重新分布注意力机制的张量并行分片，这些分片已按 TP 度缩小了规模，因此该操作中每个 rank 交换的数据量远小于可能处理完整未分片张量的集合通信。在具备高带宽 UB 平面的 CloudMatrix384 上，这两个算子的通信开销相对较小。



(a) The basic MLA flow with pure DP.

(b) Our proposed MLA flow with hybrid parallelism.

Fig. 16. prefill（预填充）阶段采用纯数据并行（DP）的基本 MLA 流程与我们提出的利用混合并行的 MLA 流程的对比。

来源：p.28 C016（原文 Fig. 16）

4.3.2 基于微批次的 prefill 流水线

为缓解专家并行引入的通信开销，原始 DeepSeek 部署采用双微批次流水线。如 Figure 18a 所示，该方法在 NVIDIA H800 GPU 上将两个并发微批次的计算与通信交错执行：将一个微批次的计算与另一个微批次的通信开销（即 Dispatch 与 Combine）相重叠，从而提升流水线效率，并在 prefill 阶段摊薄时延。

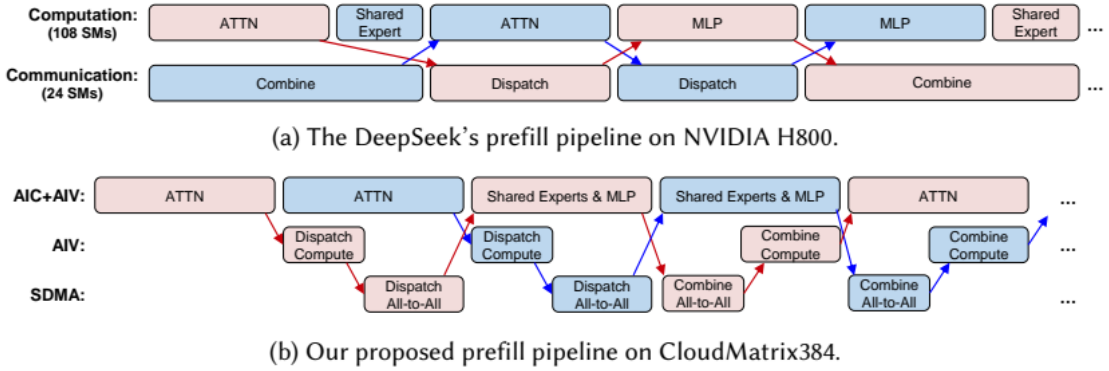


Fig. 18. prefill 流水线策略对比：(a) DeepSeek 在 H800 上的方案，为通信预留计算单元；(b) 我们在 CloudMatrix384 上提出的流水线，利用异构的 AIC、AIV 和 SDMA 单元执行专门化任务，增强计算与通信的重叠。两幅图中，交替的颜色用于区分正在处理的两个交错微批次。

来源：p.31 C018（原文 Fig. 18）

然而，由于架构不匹配，将这一策略直接移植到 CloudMatrix384 上的昇腾 910（Ascend 910）NPU 并不高效。H800 上的流水线通常预留一部分流式多处理器（SM）专门处理通信任务，借此获得并发能力，但减少了可用的计算资源。相比之下，Ascend 910 提供异构计算结构，由负责矩阵运算的 AIC、负责轻量计算的 AIV 以及负责数据搬运的 SDMA（系统 DMA）引擎组成，可实现更细粒度、按角色分工的任务分发。

为充分利用这种异构性，我们为 CloudMatrix384 引入了经优化的*基于微批次的 prefill 流水线*，如图 18b 所示。该设计将工作负载在 AIC、AIV 与 SDMA 子系统之间编排分发，具体如下：

首先，我们将低强度的辅助计算卸载到 AIV，让 AIC 专注于 ATTN、MLP 等计算密集型算子。诸如 Dispatch 之前的 token 重排与元数据生成（记为 DispatchCompute），以及 Combine 之后的专家输出累加（记为 CombineCompute）等任务，都被分配给 AIV。这些操作轻量且可向量化，非常适合 AIV 执行。如图 18b 所示，AIV 可以为一个微批次处理 DispatchCompute，同时 AIC 为另一个微批次执行核心计算，实现细粒度的算子级重叠。

其次，我们将大规模数据传输（例如 MoE Dispatch 与 Combine 的 all-to-all 通信）显式路由到 SDMA 引擎。通过将这些内存操作隔离到一条专用传输流中，可避免其与 AIC、AIV 的执行产生争用。这种隔离保证了重计算操作能够不受干扰地持续进行，而通信时延则被并发执行的 AIC/AIV 任务所掩盖。鉴于 prefill 工作负载以稠密矩阵运算和通信为主，这种经由 SDMA 的显式数据流疏导对维持 NPU 峰值吞吐量至关重要。

这种硬件感知的任务分派——即 AIC 负责主计算、AIV 负责辅助向量任务、SDMA 负责通信——提升了并发度，并将执行停顿降至最低。

此外，该设计与我们的解码阶段流水线（§4.2.3）有明显不同：后者因时延与吞吐量需求不同，通信逻辑与计算流的耦合更紧密。在 prefill 中，处理更长序列和更大微批次的需求使其对计算饱和与带宽争用更加敏感。因此，通过专用执行单元实现关注点分离，并在算子级重叠任务，更契合 CloudMatrix384 的性能特征。

4.3.3 prefill 与解码之间的低干扰切换

在 prefill-解码分离式推理服务架构中，prefill 阶段负责生成第一个 token 并产生相应的 KV 缓存，随后必须将其传输至解码阶段以启动自回归生成。为防止时延敏感的解码被 prefill 活动干扰，我们在 CloudMatrix-Infer 中引入三项系统级优化：(1) 经 RDMA 平面对 KV 缓存传输实施硬件级隔离；(2) 异步调度，将 prefill 执行与解码调度解耦；(3) 模型感知的连接分组，均衡 prefill-解码通信流量。

基于 RDMA 平面的 KV 缓存传输。prefill 阶段完成后，完整的 KV 缓存将被传输至指定的解码节点。为消除其对解码阶段通信的潜在干扰，这一 NPU 到 NPU 的传输经由 RDMA 平面进行——该平面与用于 token 分发、专家输出合并等带宽密集型解码操作的 UB 平面在物理和逻辑上均实现解耦。借助 RDMA 平面的专用路径，我们将 KV 缓存的搬运与时延敏感的解码流量隔离开。此外，由于每个请求的 KV 缓存仅传输一次，RDMA 平面可提供充足带宽而不致成为性能瓶颈。

异步 prefill 调度。为进一步降低两个阶段之间的干扰，我们将 prefill 调度与 KV 缓存传输卸载到解码调度器中的一个专用后台线程。当新的推理请求到达时，推理引擎立即将控制权交还给该后台线程，由其异步执行以下步骤：(i) 在目标解码节点上分配 KV 缓存缓冲区；(ii) 将 prefill 任务路由到低负载的 prefill 节点；(iii) 在 prefill 完成后触发基于 RDMA 的缓存传输。该设计确保解码线程绝不会被 prefill 计算或数据传输阻塞，从而实现连续的解码调度并提升响应速度。

负载均衡的 prefill-解码连接映射。在 prefill-解码分离式（PD-disaggregated）系统中，一种常见场景是 prefill 与解码阶段采用不同的并行配置。例如，解码阶段可采用张量并行（TP）与数据并行（DP）的组合，而 prefill 阶段通常使用更大的 TP 度以加速长输入序列的处理。DeepSeek-R1 模型采用单潜在头的 MLA，其一个关键特性是：TP 组（tp_rank）内的所有 rank 都持有一份完全相同的完整 KV 缓存副本。

这种数据冗余虽然带来了灵活性，但若管理不当，也会引入网络热点的风险。如果一个解码实例的所有 rank 都从同一个源 prefill rank 拉取 KV 缓存，该单条网络链路将成为严重瓶颈。为避免这一问题，我们设计了*确定性分组连接机制*以确保传输负载均衡。该映射方案的计算方式如下：设 prefill_tp_size 为 prefill 实例的 TP 规模；设 decode_tp_size 与 decode_dp_size 分别为解码实例的 TP 与 DP 规模；设 decode_tp_rank_id 与 decode_dp_rank_id 为某个解码进程的 TP 与 DP rank id。

首先确定分组参数：ratio = prefill_tp_size / decode_tp_size，group_size = decode_dp_size / ratio。

随后，每个解码 rank 按以下映射确定其源 prefill rank：group_id = ⌊decode_dp_rank_id / group_size⌋，prefill_tp_rank_id = (group_id × decode_tp_size) + decode_tp_rank_id。该方案确保所有 prefill-解码链路的连接拓扑均衡，避免通信热点并维持高吞吐量。

这三项技术相辅相成，实现了 prefill 到解码的无缝、低干扰交接，保持系统效率，并在分离式架构下保障大规模 LLM 的高性能推理服务。

4.4 基于统一内存访问的 UB 驱动分布式缓存

在云环境中高效部署 LLM，在很大程度上取决于高性能的缓存策略。此类策略对于加速数据访问不可或缺，主要面向两类关键场景：优化上下文 prefill 的历史 KV 缓存（上下文缓存，Context Caching），以及支撑快速模型部署与切换的模型参数（模型缓存，Model Caching）。有效实现这些缓存层可显著减少冗余计算、缩短模型加载时延并提升整体系统性能。支撑此类缓存功能，需要一个高性能、大容量、低时延的中间内存层，从战略上弥合 NPU 高速内存与较慢的持久化存储服务（如对象存储服务 OBS）之间的性能鸿沟。

本节详述 CloudMatrix384 上面向 LLM 推理服务的 UB 驱动分布式缓存。我们首先描述分离式内存池化这一基础（§4.4.1），它利用高带宽 UB 平面构建具备统一内存访问能力的分离式内存池；随后介绍构建于该内存池之上的两项关键缓存服务：上下文缓存（§4.4.2）与模型缓存（§4.4.3），二者均通过华为云弹性内存服务（EMS）[26] 提供。

4.4.1 分离式内存池化

EMS 缓存服务的核心是一个逻辑上分离式的内存池，由 CloudMatrix384 内跨节点聚合的 CPU 侧 DRAM 构成。该内存池作为统一的高性能内存基底，用于缓存历史 KV 缓存与模型参数。这一内存池的显著特征在于与 UB 网络的深度集成

平面，从而实现对这份分布式 DRAM 的高效统一内存访问，使 NPU 无论数据物理位于何处都能快速取回所需内容，支撑起 §4.1 所述的对等推理服务架构。该设计的有效性关键取决于 UB 的以下硬件能力：*1) 高速对等互连网络：*UB 网络支持快速的节点间数据传输，使任意 NPU 或 CPU 都能高效访问其他节点上的 DRAM；*2) UB 上的 DMA：*通过直接内存访问（DMA）实现零拷贝数据传输，绕过 CPU 中介，削减传输时延；*3) 底层内存原语：*UB 协议暴露远端内存注册与访问原语，使软件栈得以维护全局内存视图。

如图 19 所示，该分离式内存池由一个专门的三组件软件架构管理：*1) MP SDK：*嵌入 AI 应用进程之中，将上层缓存请求翻译为分布式内存操作，对外暴露 Put、Get 等键值存储风格的 API；*2) MP Controller：*集中式控制平面，维护元数据（如分布式哈希表（DHT）视图、命名空间），协调操作并统筹资源管理；*3) MP Server：*部署在贡献 DRAM 的节点上，管理本地内存，处理分层与恢复，并参与负载均衡。

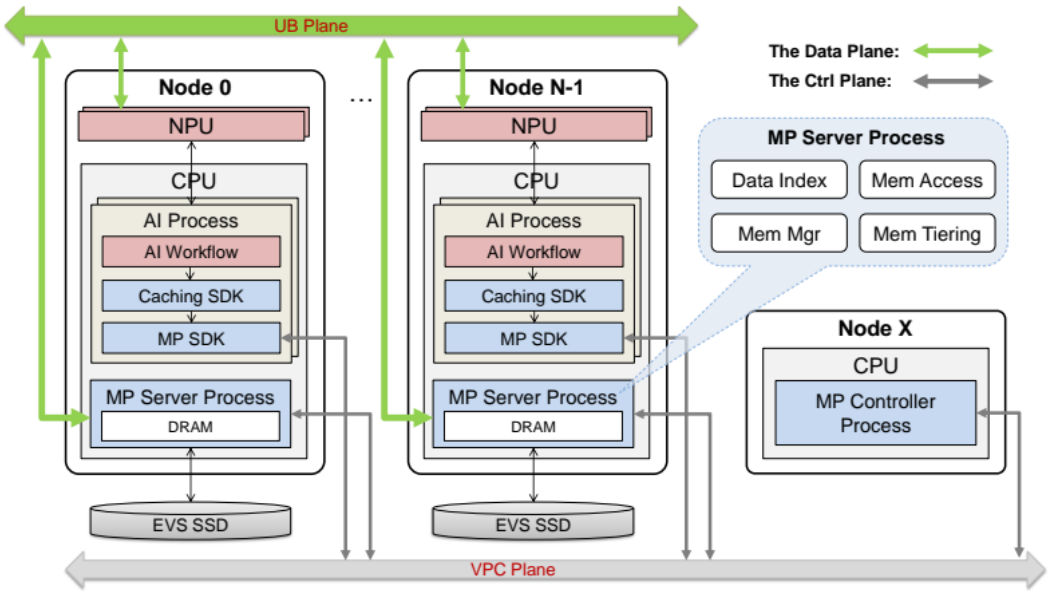


Fig. 19. 弹性内存服务（EMS）中由 UB 驱动的分离式内存池的部署架构。

来源：p.33 C019（原文 Fig. 19）

这些软件组件与 UB 平面的协同，催生了若干关键运行机制与系统特性：

分布式数据索引与放置。为确定一个键值对在分离式内存池中的放置位置并高效定位它，内存池采用*全局一致性哈希*索引。该索引将输入键映射到负责它的 MP Server 节点；由 MP Controller 管理整体一致性与元数据的 DHT 视图则是这一方案的基础。各 MP Server 通过管理本地的数据分片并响应被路由来的请求参与 DHT。MP SDK 利用该机制将键分布到具体节点与 DRAM 地址以完成数据访问。

高性能远端内存访问。由 UB 平面使能、并受上述软件组件管理的一项关键功能，是 NPU 对远端 DRAM 的直接高性能访问。这涉及在

MP Server 实例与 MP SDK 客户端初始化期间建立的内存映射与注册流程。在此过程中，系统通过协商控制消息来交换划拨给内存池的 DRAM 段物理地址范围，随后将这些地址范围注册到 UB 网络与 MP Controller。这种跨节点映射能力依托 CloudMatrix384 超节点对全局统一内存寻址与路由的支持，使 UB 交换机能够将 NPU 发起的 SDMA 驱动的访问请求直接路由到目标 MP Server 所管理的 DRAM。

细粒度本地内存管理。为有效管理所分配的 DRAM 段并对抗变长数据对象（如 KV 缓存块或模型分片）造成的碎片化，每个 MP Server 采用多粒度内存分配系统。其中一个关键点是使用*大页（huge pages）*来降低内存切片分配的频率及相关管理开销。在数据分配方面，系统支持变长内存分区，相比固定尺寸分配器显著提升内存利用率。此外，MP Server 允许内存在其管理的 DRAM 内不同粒度之间动态流动，依据随工作负载而变的访问模式提升资源效率。

带持久化与恢复的内存分层。为控制存储成本并保证数据持久化，分离式内存池纳入了一个由 MP Server 管理的基于 SSD 的分层。该层利用云上提供的弹性云硬盘（EVS）SSD 提供大容量持久化存储。除基于 EVS 的分层外，另一种选择是使用云的弹性文件服务（SFS），但成本更高。在这一层级结构中，分布式 DRAM 池充当位于 EVS 层之上的快速缓存，实现对高频访问数据的低时延访问。持久化通过将所有数据写入 EVS 来保证。由于 EVS 卷容量有限，系统采用本地淘汰策略（如最近最少使用，LRU）在需要时释放空间。MP Server 独立管理 DRAM 驻留，对 DRAM 层使用自己的 LRU 淘汰逻辑与

容量阈值。从 DRAM 中淘汰的数据仍持久保存在 EVS 中，除非其后被 EVS 自身的空间管理例程清除。这种分层结构确保了容错能力：若内存中数据丢失（如因节点故障），只要其未被淘汰，即可从 EVS 层恢复。

重要的是，尽管通过擎天（Qingtian）网卡访问 EVS 的单节点带宽相对有限（通常低于 400 Gbps），CloudMatrix384 中的分离式内存池将全部 48 个节点的带宽聚合起来，使 EVS 总访问带宽最高可达 48 × 400 Gbps。由于数据被切分为细粒度块并分布到各节点，NPU 可以经由高带宽 UB 平面并发地从多个节点抓取这些块。这样，即使请求的数据位于 EVS 层，也能获得很高的聚合加载带宽，通过全系统并行有效摊薄了单节点 EVS 访问的限制。

命名空间隔离。为支持多租户并管理不同上下文缓存与模型缓存实例的数据，分离式内存池提供 KV Namespace 隔离。这主要由 MP Controller 统筹，其负责命名空间的创建、删除与元数据管理。每个 MP Server 都感知活跃的命名空间，并确保数据操作被限制在指定命名空间内，从而在共享内存池中提供逻辑上的数据隔离与容量使用限制。

总而言之，CloudMatrix384 的 UB 驱动分离式内存池为 LLM 推理提供了高吞吐量、可扩展的内存层。通过将硬件级对等访问与分布式内存管理软件相结合，该系统同时支持对 KV 缓存与模型参数的高效缓存，构成 EMS 的骨架。

4.4.2 上下文缓存

LLM 推理的 prefill 阶段负责处理输入提示并生成初始 KV 缓存，该阶段计算密集，对长序列尤甚。通过复用先前请求的历史 KV 缓存，可以获得可观的性能收益。这是

在涉及重复前缀的场景（如多轮对话、few-shot 提示、重复的系统指令）中尤其有价值。在我们的架构中，*上下文缓存（Context Caching）*指专门用于存储并高效检索这些历史 KV 缓存的机制。

上下文缓存由 EMS [26] 实现，它是华为云上的一项服务。EMS 利用 UB 驱动的分离式内存池（§4.4.1）为历史 KV 缓存构建一个共享的分布式存储库。这些缓存按模型特性与 UB 传输效率组织成分页块（例如每块 128–512 个 token）。推理集群中的所有 NPU 都可以通过 EMS API 访问该缓存或向其贡献数据。

索引、去重与检索。EMS 向上层 LLM 推理服务框架提供专门的上下文缓存 SDK（即 API 层），用于存储和检索历史 KV 缓存块。在内部，该 EMS SDK 利用 MP SDK（§4.4.1）的 API 与底层分布式 DRAM 及分层存储交互。每个 KV 缓存块关联一个由其 token 序列派生的唯一哈希键，并附加前缀哈希以支持内容寻址索引。由此可实现快速查找与去重：相同的 KV 块只存储一次，并可跨请求复用。

分配给上下文缓存的分离式内存池份额受容量约束制约。当接近这些上限时，MP Server（§4.4.1）会触发将较冷的 KV 缓存块从 DRAM 淘汰到 EVS 支撑的 SSD 层。若 SSD 容量也受限，则基于 LRU 类策略将数据彻底删除。这一淘汰过程确保上下文缓存与模型缓存在统一内存池内公平、高效地共享资源。

与 prefill-解码-缓存分离（PDC 分离）的交互。EMS 与分离式的 prefill 与解码流水线紧密集成：

*prefill——复用与存储：*收到新请求后，prefill 引擎以输入前缀的哈希查询 EMS，以识别可复用的 KV 缓存块。若命中，这些块经 UB 平面取回并直接加载进 NPU 内存，从而跳过冗余计算。随后引擎

处理剩余的后缀部分并生成相应的 KV 缓存块。这些新块被异步写回 EMS，供未来请求复用，且不会阻塞正在进行的计算。

*解码——选择性缓存存储：*解码阶段生成的 KV 缓存对非推理模型可以复用，但对 DeepSeek-R1 这类推理模型则不然。这些推理模型先输出中间推理 token，再输出最终回答 token。中间 token 通常不会在后续轮次被重新摄入，因此当最终回答 token 被纳入后续 prompt 时，其位置会发生偏移。由于注意力对位置敏感，这种位置变化会破坏缓存有效性。因此，解码生成的缓存通常不纳入存储。不过，若系统采用可容忍位置偏移的近似 KV 复用技术，则有选择地存储最终回答 token 的缓存块可带来性能收益。

4.4.3 模型缓存

现代 LLM 推理服务基础设施必须高效支撑在规模、架构与任务特化上各异的多模型组合，还须应对服务需求波动与持续模型更新所带来的动态模型切换。然而，将数十亿参数级的 LLM 从持久化存储（如对象存储服务 OBS）加载到 NPU 内存会产生显著时延。例如，按每桶 2.5 GB/s 的标准访问带宽计算，从 OBS 加载 671B 参数的 DeepSeek-R1 模型需要五分钟以上。这一时延严重限制动态模型切换的实用性，并损害服务响应能力，在模型更新或 A/B 测试期间尤为明显。因此，快速的缓存机制不仅对缓解上述开销必不可少，也是保障模型部署敏捷响应的必要条件。

为应对这些挑战，我们引入了 EMS 提供的模型缓存。其核心在于，EMS 将 UB 驱动的分离式内存池（§4.4.1）用作高性能分布式缓存底座，以支撑跨系统的低时延模型访问。为与上层推理服务框架集成，EMS 提供模型缓存 SDK，暴露用于检查、预取和从缓存加载模型的 API。具体而言，该 SDK 允许用户查询某模型当前是否缓存在 EMS 内存池中、发起将模型块从持久存储异步预取到 EMS 的操作，以及触发将模型块加载到目标 NPU 内存以供推理。当模型已被部分缓存时，预取相当于一种提示，促使数据块从较慢层（如 SSD）提升到较快层（如 DRAM），进一步优化访问时延。

缓存管理策略。在内部，EMS 将每个模型分解为内存块，并以键值条目的形式存入分离式内存池。一个集中式元数据服务跟踪每个模型到其对应块集合的映射，从而支持细粒度的分片化模型加载以及推理期间的高效检索。EMS 通过覆盖准入、淘汰与版本管理的协同策略管理缓存的模型块。在准入与预取方面，EMS 依据应用提示与观测到的访问模式，将模型块加载到 DRAM 或 SSD 层。淘汰由分离式内存池原生的基于 LRU 的策略处理；由于模型块的访问行为具有一致性，该策略通常以模型级粒度运作，即整个模型或大段被一并淘汰，避免产生碎片化状态。在版本管理方面，EMS 通过维护版本感知的标识符并将每个模型与其对应的块集相关联，确保 NPU 始终执行正确的模型版本。部署新版本时，推理服务框架会显式请求该版本，而旧版本则随着自然的缓存淘汰逐渐退场。

模型缓存依托 UB 驱动分离式内存池的收益。EMS 借助 UB 驱动的分离式内存池，为模型缓存带来两大关键优势。其一，高带宽、低时延的 UB 平面支持模型块从 EMS 各内存层（如 DRAM 或 SSD）向 NPU 内存的快速传输，显著降低模型加载时延。其二，EMS 使用全集群统一的内存池，消除了数据冗余，使单一缓存模型版本可被所有 NPU 实例共享。这一设计既减轻了持久存储带宽的压力，又降低了缓存所需的 DRAM 与 SSD 总占用，带来更好的可扩展性与资源效率。

表 1 通过对一个 671B 参数、INT8 量化的模型在不同模型加载策略下的性能对比，量化了这些收益。不使用缓存时，8 个模型实例同时从对象存储（OBS）加载模型，由于共享的 2.5 GB/s OBS 带宽上发生严重争用，每个实例的冷启动时延约为 2,560 秒。本地 DRAM 缓存无法改善该冷启动时延，因为每

个节点仍要独立地从 OBS 拉取完整模型。相比之下，EMS 通过内存池实现共享加载并跨实例复用模型块，将冷启动时延降至仅约 320 秒。

Scenario	Metric	No Cache (OBS Load)	Local DRAM Cache	EMS
Model Load	Cold Start Latency (Initial OBS to NPU, s)	~2,560[1]	~2,560[1]	~320
	Warm Start Latency (DRAM to NPU, s)	N/A	~5	~5
	DRAM Capacity Overhead (× Model Size)	0	8 ×	1 ×
Model Switch	Cache Hit Rate (%)	0	12.5%	100%[2]
	Average Latency to Switch (s)	~320	~281	~5

[1] When 8 instances concurrently load the same model from the shared OBS bucket, reflecting significant contention.
[2] Assumes the capacity of EMS exactly holds all 8 distinct 671B active model versions.

Table 1. 在 CloudMatrix384 内将一个 671B INT8 模型（数据量约 671GB）加载到 8 个模型实例的不同模型加载策略的性能对比（模型最初存储在带宽为 2.5GB/s 的对象存储（OBS）桶中。我们考虑两种场景：1) 模型加载：8 个实例采用不同加载策略并发加载同一模型，比较其加载时延与 DRAM 开销；2) 模型切换：在 8 个不同模型同时活跃的情况下，比较某一实例随机切换到这 8 个模型之一时的模型切换时延与缓存命中率。表中时延为示意值，能够代表所定义场景下的典型水平。）

来源：p.36 C020（原文 Table 1）

除时延外，EMS 还提升了内存效率。本地 DRAM 缓存带来 8 倍 DRAM 开销，即 8 个实例各自保存一份完整模型副本；相比之下，EMS 只需 1 倍 DRAM 占用即可服务所有实例，同时保持相同的约 5 秒热启动时延。在模型切换场景中，EMS 实现了 100% 的缓存命中率，平均切换时延约 5 秒，显著优于本地 DRAM 缓存——后者命中率仅 12.5%，时延约 281 秒。这些结果凸显出 EMS 是大规模推理环境中同时最小化模型访问时延与内存资源开销的高效方案。

4.5 INT8 量化

为在 Ascend 910 平台上对 DeepSeek-V3/R1 等大规模 MoE 模型实现高吞吐、低时延推理，我们设计并实现了一种免训练的层次化 INT8 量化方案，作用于模型权重与激活值。该方案旨在最大化计算效率并缩减内存占用，同时审慎管控潜在的精度损失。我们方法的核心组成部分详述如下：

混合精度策略。我们的量化方案采用*混合精度策略*，依据各算子对整体性能的影响（如计算负载、内存访问）与其对数值精度的敏感度之间的权衡，对模型中不同算子进行分类。关键执行路径上计算最密集的操作，如前馈网络（FFN）和注意力机制中的大规模矩阵乘法，被量化为 INT8 以获取最高吞吐量。反之，对量化误差更敏感、但在整体内存访问或计算负担中占比较小的子模块或特定操作（如某些归一化层或关键门控机制），则用 BF16 或 FP32 保留更高精度。这种灵活的位宽划分确保整个模型能在统一的硬件流水线中高效执行，同时避免在关键且数值敏感的路径上出现精度瓶颈。

自适应缩放因子搜索。有效的量化需要将浮点值的动态范围仔细对齐到 INT8 整数的有限范围。对于每个待 INT8 量化的权重张量和激活张量，我们引入一个轻量的*自适应缩放因子搜索过程*。$s \star$ 该过程自动确定使量化误差最小化的最优缩放因子，使量化前后的数值分布得到有效对齐。缩放因子搜索被表述为一个优化问题：

$$s^{*} = \arg\min_{s} L(s)\text{，其中 } L(s) = \|Q(W \cdot s)(s^{-1} \cdot X) - WX\| \tag{3}$$

自适应缩放搜索：量化前后输出对齐的优化目标（符号保持原样，已对照原 PDF 裁片核验。）

s 其中，W 表示权重，X 表示激活值，Q(·) 表示量化函数。该公式旨在为权重求出缩放因子 s（为激活值求出 s − 1），使量化运算的输出 Q(W · s)(s − 1 · X) WX 最接近原始浮点输出。整个缩放因子的确定过程在量化后校准步骤中离线完成，因而在推理期间不会引入任何额外运行时开销。这一概念涉及在量化乘法之前，先以适当的缩放因子对 XW 进行变换。

离群值抑制与结构变换。大模型中的某些组件，尤其是 MoE 架构中的特定专家子网络或门控结构，其激活值或权重分布可能呈现长尾或显著离群值。这些离群值会对量化范围产生不成比例的影响，导致大多数数值出现精度损失。为缓解这一问题，我们采用一种*基于结构变换的离群值抑制技术*：在量化之前引入简单的线性变换（概念上类似于施加学习得到的正交基旋转，或将缩放因子吸收进前序/后继层）。这些变换旨在把极端值重新分布到更均衡、更利于量化的数值范围内，同时不改变该层原本的数学函数。通过降低离群值的影响，该方法最大程度地减小了出现大量化误差的风险，并抑制了误差在网络中的后续放大。

高效的 INT8 矩阵乘算子。INT8 量化的性能收益在很大程度上取决于高度优化的执行算子。我们为矩阵乘采用*X/W 混合粒度量化方案*：激活值（X）按 token 粒度量化（动态范围逐 token 确定），而权重（W）按通道粒度量化（通常为逐输出通道、每通道静态范围）。该方案既满足了适应快速变化的激活统计特性的需要，又兼顾了保持权重表示稳定性的诉求。这种混合粒度，再加上为权重与激活精心对齐的内存布局，使 Ascend NPU 上专用的整数矩阵乘指令得以被充分利用。与等效的 BF16 或 FP16 实现相比，这些优化后的 INT8 算子在同一硬件上可带来数倍的推理吞吐量提升，同时确保任何精度下降都保持在应用可接受的容差范围内。

块级裁剪与误差补偿。为进一步提升精度并处理大型权重张量内部的局部差异，我们实现了*块级裁剪与误差补偿*。先对权重进行统计分析并划分为较小的块，然后为每个块建立一个独立的、可容忍的裁剪范围。该范围可通过为裁剪优化缩放因子 α 来确定（例如 W = α · max(W) 与 W = α · min(W)），使该特定块的 clip_max block clip_min block 量化误差最小化，例如通过求解：XWXQWα

$$\arg\min_{\alpha} \|\mathrm{Block}(X;W) - \mathrm{Block}(X;Q(W;\alpha))\| \tag{4}$$

块级裁剪：逐块求解最优裁剪因子 α（符号保持原样，已对照原 PDF 裁片核验。）

α 其中，Q(W; α) 表示以截断因子 α 对块内的权重 W 进行量化。同时，轻量级的误差补偿项被策略性地插入推理计算图中。这些项旨在抵消或部分纠正量化在模型不同位置引入的系统性误差，从而缓解量化噪声对最终模型输出的累积影响。该方法的一个显著优势在于：既无需修改原始模型训练过程，也不依赖额外的微调阶段，便于快速部署与迭代。

这五种策略相互配合，构成了一个稳健且分层的 INT8 量化框架，使 DeepSeek-V3/R1 这类超大模型能够在 Ascend 硬件上进行高性能推理，并在计算效率与模型精度保持之间实现了精心平衡。

考察所采用的各种优化技术的具体贡献（§5.4）；最后是关键底层算子的性能分析（§5.5）。

5.1 实验设置

我们的评估在一台由华为云 ModelArts Lite（集群模式）服务提供的华为 CloudMatrix384 超节点上进行。具体而言，我们采用单个 CloudMatrix384 中 256 个 Ascend 910 NPU 及其配套鲲鹏 CPU 的配

置。推理服务系统由华为与 SiliconFlow 联合优化的 LLM 推理引擎构成，并部署了必需的华为 CANN 软件包。华为云的弹性内存服务（EMS）提供分布式缓存能力（详见 §4.4），已预部署于所分配的计算节点。整个部署遵循我们提出的带 PDC 分离的对等推理服务架构（§4.1），各逻辑集群的具体配置如下：

解码集群：我们部署单个解码实例，使用 160 个 Ascend 910 NPU（分布在 20 个计算节点上，即 320 个 NPU 芯粒）。该实例对稀疏 MoE 层采用 320 的专家并行度（EP320）；对于 MLA 和密集 FFN 层等其他组件，则在全部 NPU 芯粒上采用 320 的数据并行度（DP320）。在这 320 个 EP rank 中，每个 rank 部署一个专家实例。专家配置包括 32 份共享专家副本、256 个不同的路由专家，以及额外的 32 个冗余路由专家，用于支持专家并行负载均衡（EPLB）。

prefill（预填充）集群：prefill 集群由 6 个 prefill 实例组成，每个实例分配 16 个 Ascend 910 NPU（每个实例 2 个计算节点，即 32 个 NPU 芯粒）。prefill 集群总计使用 96 个 NPU。每个 prefill 实例对稀疏 MoE 层采用 32 的专家并行度（EP32）。prefill 实例中的 MLA 组件采用 §4.3.1 详述的混合并行策略。在每个 32-rank 的 prefill 实例内部，每个 rank 配置 10 个专家，包括 1 个共享专家、8 个路由选择的专家和 1 个冗余路由专家，以实现有效的 EPLB。

缓存集群（弹性内存服务，EMS）：EMS 提供的分布式缓存通过利用构成 prefill 与解码集群的全部物理计算节点的主机 CPU DRAM 来实现。这 32 个计算节点（解码集群 20 个 + prefill 集群 12 个）上的鲲鹏（Kunpeng）CPU 及其配套 DRAM 共同构成由 UB 驱动的分离式内存池。EMS 将该池同时用于模型缓存（Model Caching，§4.4.3）与上下文缓存（Context Caching，§4.4.2）。所有 NPU 对该共享内存池的访问依托 CloudMatrix384 的高速 UB 平面完成。

上述实验配置是后文精度与性能评估的基础。所评估的 DeepSeek-R1 模型为 671B 参数版本，已量化为 INT8（§4.5）以在 Ascend 910 NPU 上执行。

5.2 整体性能

本节将 CloudMatrix-Infer 的整体性能与领先基线进行对比评估，针对 prefill 与解码两个阶段同时度量原始吞吐量与硬件效率（tokens/s/TFLOPS）。我们将这些指标与公开可得的 DeepSeek 在 NVIDIA H800 GPU 上的服务性能数据 [12] 以及 SGLang 在 NVIDIA H100 GPU 上的性能数据 [53] 进行比较。我们对 prefill 与解码阶段分别独立评估，与对比来源所报告的实验设置保持一致，以便进行清晰的分析。

prefill 吞吐量。我们首先考察 prefill 吞吐量，这是高效处理输入提示词的关键因素。Table 2 详细列出了按每加速器口径的对比。有效的 MoE 模型 2 https://www.siliconflow.com/

Method	Batch Size	Input Length	Throughput (tokens/s)	Throughput per TFLOPS
DeepSeek on H800 (Blog)	N/A	N/A	4,026	2.03
SGLang on H100 (Default)	16,384	4,096	6,288	3.18
CloudMatrix-Infer (Default)	16,384	4,096	5,655	3.76
DeepSeek on H800 (Profile)	16,384	4,096	**7,839**	3.96
SGLang on H100 (Perfect EPLB)	16,384	4,096	7,417	3.75
CloudMatrix-Infer (Perfect EPLB)	16,384	4,096	6,688	**4.45**

Table 2. DeepSeek-R1 的整体 prefill 吞吐量（每加速器）。

来源：p.40 C021（原文 Table 2）

推理服务在 prefill 阶段同样在很大程度上依赖健壮的 EPLB，这一点在 SGLang 的分析 [53] 中被重点指出。DeepSeek（Profile）数据吞吐量很高（每 GPU 7,839 tokens/s），可能反映的是接近理想专家负载均衡下的性能。为了与这类优化场景建立可比的分析基线，Table 2 为 SGLang 与 CloudMatrix-Infer 均列入了 *Perfect EPLB* 配置。这些结果表示在专家间完全均匀负载分布的理想化假设下的预测性能。

在默认配置下，CloudMatrix-Infer 每 NPU 处理 5,655 tokens/s，计算效率为 3.76 tokens/s per TFLOPS。尽管 SGLang 在 NVIDIA H100 上的默认配置原始吞吐量略高，其效率（3.18 tokens/s per TFLOPS）仍明显低于我们。在理想化的 "Perfect EPLB" 条件下测试时，CloudMatrix-Infer 达到每 NPU 6,688 tokens/s，折合 4.45 tokens/s per TFLOPS 的效率，同时超越了 SGLang 在 H100 上的理想效率（3.75 tokens/s per TFLOPS）与 DeepSeek 在 H800 上的 Profile 效率（3.96 tokens/s per TFLOPS）。这些对比凸显了 CloudMatrix-Infer 的强劲潜力，而我们默认结果与理想结果之间的差距也表明负载均衡算法仍有进一步改进空间。

解码吞吐量。接下来，我们分析自回归解码阶段的性能，详见 Table 3。我们评估在每 token 输出时间（TPOT）低于 50 ms 的服务级目标（SLO）约束下的绝对解码吞吐量（tokens/s），同时评估按加速器算力归一化的吞吐量（tokens/s per TFLOPS），作为计算效率的指标。值得注意的是，SGLang（Simulated MTP）与 CloudMatrix-Infer 两种配置均采用了多 token 预测（MTP），并假设单个投机 token 的有效接受率为 70%。

Method	Batch Size	KV Cache Length	TPOT (ms)	Throughput (tokens/s)	Throughput per TFLOPS
DeepSeek (Blog) on H800	N/A	4,989	~50.0	1,850	0.93
DeepSeek (Profile) on H800	128	4,096	~50.2	**2,325**	1.17
SGLang (Simu. MTP) on H100	128	4,000	~55.6	2,172	1.10
CloudMatrix-Infer	96	4,096	49.4	1,943	**1.29**

Table 3. DeepSeek-R1 的整体解码吞吐量（每加速器）。

来源：p.40 C022（原文 Table 3）

CloudMatrix-Infer 配置为每 NPU batch size 96、KV 缓存长度 4,096 tokens，实现了 49.4 ms 的优异 TPOT。在绝对系统吞吐量方面，CloudMatrix-Infer 在 batch size 为 96 时达到每 NPU 1,943 tokens/s，高于 DeepSeek（Blog）在 H800 上的基线（每 GPU 1,850 tokens/s）。虽然数值上低于 DeepSeek（Profile）在 H800（每 GPU 2,325 tokens/s）和 SGLang 在 H100（每 GPU 2,172 tokens/s）上的结果，但后两个系统是在更大的 batch size 128 下测得的。每 TFLOPS 吞吐量指标进一步揭示了系统计算效率：CloudMatrix-Infer 取得了最高的计算效率（1.29 tokens/s per TFLOPS），高于 SGLang 在 H100 上的 1.10 tokens/s per TFLOPS、DeepSeek（Blog）在 H800 上的 0.93 tokens/s per TFLOPS，以及 DeepSeek（Profile）在 H800 上的 1.17 tokens/s per TFLOPS。这表明我们的推理服务方案在解码阶段有效利用了 CloudMatrix384 的可用算力。

TPOT SLO (ms)	Prompt Length	Output Length	Batch Size	Achieved TPOT (ms)	Throughput per NPU (tokens/s)
50	1,024	1,024	128	46.8	2,733
50	2,048	256	112	47.4	2,360
50	4,096	256	96	49.4	1,943
30	4,096	256	24	24.6	974
15	4,096	256	8	14.9	538

We also evaluate the decode throughput of CloudMatrix-Infer under varying TPOT service-level objectives (SLOs) and different prompt and output lengths, as shown in Table 4. The results show a clear trend: decode throughput significantly increases with shorter combined prompt and output lengths. For instance, with prompt and output lengths of 1,024 tokens each, the decode throughput reached 2,733 tokens/s per NPU. This dropped to 2,360 tokens/s per NPU when the prompt length increased to 2,048 tokens and the output to 256 tokens. This improvement is attributed to shorter total lengths reducing the KV cache space required per request, which in turn allows for larger batch sizes. Moreover, as the TPOT SLO becomes more stringent, from 50 ms to 15 ms, CloudMatrix-Infer adjusts the batch size accordingly to meet latency targets. Under a relaxed SLO of 50 ms, CloudMatrix-Infer supports a batch size of 96 and achieves a throughput of 1,943 tokens/s per NPU while satisfying the latency constraint. As the SLO tightens to 30 ms and 15 ms, the batch sizes reduce to 24 and 8 respectively, resulting in lower throughputs of 974 and 538 tokens/s per NPU. These findings demonstrate CloudMatrix-Infer's ability to meet diverse latency constraints by dynamically scaling batch sizes, all while maintaining high decoding throughput even under stringent real-time demands.

Table 4. CloudMatrix-Infer 在不同每 token 输出时间（TPOT）服务级目标（SLO）与 prompt/输出长度下的解码吞吐量。

来源：p.41 C023（原文 Table 4）

5.3 精度

为全面评估 DeepSeek-R1 量化至 INT8 并部署于 CloudMatrix384（下文简称 DeepSeek-R1 (INT8)）后的推理精度，我们基于广泛使用的基准测试开展了大量测试。评估重点在于，将 SiliconFlow 实现的 INT8 量化（§4.5）与官方 DeepSeek-R1 API [10] 的结果及其技术报告 [13] 公布的结果进行精度对比。鉴于原版 DeepSeek-R1 技术报告未完整披露各基准测试的全部测试参数，直接复现可能产生偏差，我们采用并排评估

方法与在线 DeepSeek-R1 API 进行对照，以确保对实际性能的比较公平且直接。

我们的评测套件源自 DeepSeek-R1 技术报告中的详尽清单以及其他广泛使用的 benchmark，共包含 16 个不同的 benchmark，用于多维度评估。排除项包括 AlpacaEval 2.0 [17] 与 Arena-Hard [36]——它们依赖 GPT-4 进行 3 评测（超出我们当前的实验条件），以及 CodeForces——因其缺乏现成的自动化评测脚本。所选 benchmark 覆盖广泛的能力维度：英文（MMLU [23]、MMLU-Pro [9]、DROP [16]、IFEval [58]、GPQA Diamond [50]、SimpleQA [44]），代码生成（LiveCodeBench [31]、HumanEval [7]），数学（AIME 2024 [3]、MATH-500 [24]、CNMO 2024 [1]、MGSM [51]），以及中

文（CLUEWSC [55]、C-Eval [25]、C-SimpleQA [22]、C-MMLU [35]）。我们相信这一精选集合为精度评估提供了稳健的基础。

为保证评估的一致性，MMLU、DROP、MGSM、GPQA Diamond、HumanEval、MATH-500、SimpleQA 与 C-SimpleQA 等 benchmark 的提示词取自 simple-evals 框架；其余 benchmark，包括 CMMLU、C-Eval、LiveCodeBench、IFEval 与 CLUEWSC，则使用 OpenCompass 框架 4。遵循 DeepSeek-R1 技术报告中的方法，MMLU-Pro、C-Eval 与 CLUEWSC 在 zero-shot 设置下测试，其他测试集遵循其原始协议。数学竞赛类 benchmark（AIME 2024 与 CNMO 2024）各进行 32 次重复测试，以准确估计其 pass@1 指标。对于 *MATH-500*、*SimpleQA* 与 *C-SimpleQA* 这些官方评估据报道使用了不同版本 GPT-4 的 benchmark，我们 5 采用 Qwen2.5-72B-Instruct 作为评分模型，对 DeepSeek-R1（INT8）与 DeepSeek-R1 API 的输出进行评估。虽然这一选择确保了本研究内部的评估一致性，但与 DeepSeek-R1 技术

3 https://codeforces.com 4 https://github.com/open-compass/opencompass 5 https://huggingface.co/Qwen/Qwen2.5-72B-Instruct

报告中的分数相比，由于后者依赖基于 GPT-4 的评分，可能存在一定偏差。关键生成参数包括温度 0.6 与 top-p 0.95，与 DeepSeek-R1 技术报告 [13] 中指定的设置保持一致。

对比精度结果见 Table 5。总体而言，我们在 Ascend 910 上实现的 DeepSeek-R1（INT8）表现出与官方 DeepSeek-R1 API 以及原技术论文所报告指标大体相当的性能。这表明为部署到 Ascend 910 而实施的 INT8 量化在多样化的任务上有效保持了模型能力。

Category	Benchmark (Metric)	DeepSeek-R1 (INT8)	DeepSeek-R1 API	DeepSeek-R1 Report
English	MMLU (Pass@1)	90.82	91.05	90.8
	MMLU-Pro (EM)	83.91	83.82	84.0
	DROP (3-shot F1)	90.42	91.02	92.2
	IF-Eval (Prompt Strict)	83.55	83.92	83.3
	GPQA Diamond (Pass@1)	71.66	71.77	71.5
	SimpleQA (Correct)	30.60	30.69	–
Code	LiveCodeBench (Pass@1-COT)	63.80	63.44	65.9
	HumanEval (Pass@1-COT)	91.83	91.85	–
Math	AIME 2024 (Pass@1)	78.96	78.12	79.8
	MATH-500 (Pass@1)	94.46	94.62	–
	CNMO 2024 (Pass@1)	77.95	76.70	78.8
	MGSM	92.40	92.65	–
Chinese	CLUEWSC (Test)	94.67	94.98	–
	C-Eval (EM)	82.05	79.92	–
	C-SimpleQA (Correct)	74.70	75.43	–
	C-MMLU	90.76	90.84	–

Table 5. 在多个 benchmark 上对 DeepSeek-R1 的精度比较，包括 Ascend 910 上经 INT8 量化的版本、DeepSeek-R1 官方 API [10]，以及 DeepSeek-R1 技术报告 [13] 中报告的结果（测试配置被视为不一致的 benchmark 结果已被排除）。

来源：p.42 C024（原文 Table 5）

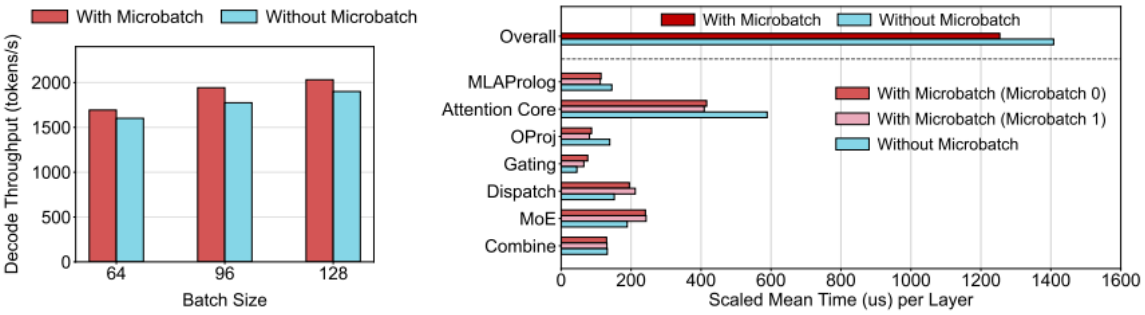
5.4 消融实验

为理解 CloudMatrix-Infer 所采用关键优化技术的各自贡献与有效性，我们开展了一系列消融研究。这些研究隔离出以下因素的影响：面向 prefill 与解码两阶段的微批次流水线策略、多 token 预测（MTP）机制，以及基于 EMS 的上下文缓存。

5.4.1 基于微批次的流水线

本消融研究通过比较启用与不启用微批次优化时的系统性能，量化基于微批次的流水线策略带来的性能影响。

解码流水线。我们首先评估前文 §4.2.3 详述的解码阶段基于微批次的流水线。该消融实验对比启用与不启用这一微批次优化时的系统性能。Figure 20a 展示了不同 batch size 下的解码吞吐量。我们观察到，启用基于微批次的流水线后，batch size 为 64、96 和 128 时解码吞吐量分别提升 5.8%、9.4% 和 6.9%。这一收益虽然有益，但与其他平台报道的潜在改进（例如 SGLang [53] 在 NVIDIA H100 集群上称达 35%）相比相对温和。这一差异主要归因于：与通常采用 RDMA 的 NVIDIA GPU 集群相比，CloudMatrix384 凭借高性能 UB 平面，其 MoE 分发（dispatch）与合并（combine）的通信开销本身更低（详见 Section 5.5.1）。由于 UB 平面上的 MoE 通信停顿更小，通过微批次实现通信隐藏所能带来的改进上限对 CloudMatrix384 而言自然更受限制。



(a) Decode throughput.

(b) Decode latency breakdown (batch size 96).

Fig. 20. 采用与不采用基于微批次的流水线时的解码吞吐量与每层时延分解。所有请求的 KV 缓存长度均为 4,096 token。在 (b) 中，带 Microbatch 的“Overall”表示两个微批次（Microbatch 0 与 Microbatch 1）重叠后的每层时延。

来源：p.43 C025（原文 Fig. 20）

Figure 20b 给出了 batch size 为 96 时解码执行的逐层时延分解。结果显示，尽管门控（Gating）、分发（Dispatch）、MoE 等阶段的单个微批次执行时延因每流计算资源减少（例如

AIC 数量从 24 减至 16）而略有增加，基于微批次的流水线仍显著改善了整体性能。其机制在于让不同微批次的注意力路径（Stream 0）与 MoE 路径（Stream 1）有效重叠，使整体逐层时延降低约 10%，并相应带来端到端解码吞吐量的可观提升。

prefill 流水线。接下来，我们考察所提出的基于微批次的 prefill 流水线的影响，详见 Section 4.3.2。Figure 21a 展示了不同提示词长度下的 prefill 吞吐量，对比启用与不启用该流水线的性能。我们观察到，在所有测试配置中，启用基于微批次的流水线可使 prefill 吞吐量显著提升 23% 至 31%。此外，

prefill 吞吐量随提示词长度增加而下降。这一趋势的原因在于，注意力计算的每 token 执行时延随提示词长度增加而上升。

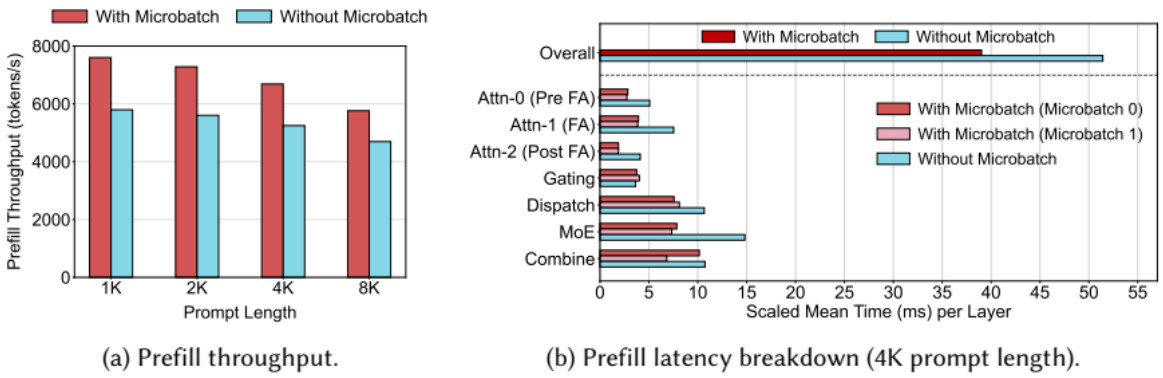


Fig. 21. 采用与不采用基于微批次的流水线时的 prefill 吞吐量与每层时延分解。所有实验均以每 NPU 共含 16K token 的批次执行。在 (b) 中，带 Microbatch 的“Overall”表示 Microbatch 0 与 Microbatch 1 重叠后的每层时延。

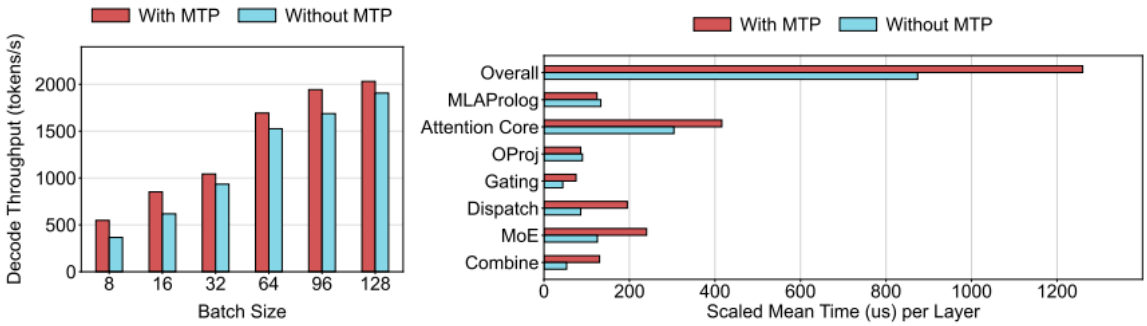
来源：p.44 C026（原文 Fig. 21）

Figure 21b 给出了 4K 提示词长度下请求执行的相应逐层时延分解。数据显示，微批次流水线启用时，每层整体执行时延降低约 24%。这一可观收益主要来自：将与通信相关的轻量计算任务（如 DispatchCompute、CombineCompute）卸载到 AIV，并让 SDMA（系统 DMA）引擎专职执行批量数据传输（如 MoE 的 All-to-All 通信）。这一策略使上述操作的执行时延能够与 AIC 上执行的核心计算（如 ATTN 与 FFN）有效重叠，从而带来更高的 NPU 利用率和更短的端到端 prefill 时间。

5.4.2 多 token 预测（MTP）

为专门量化典型条件下 MTP 机制的性能贡献，我们开展了针对性消融研究。该评估聚焦 MTP 在每个解码步生成单个投机 token 的场景，在 CloudMatrix384 上采用一致的 4K token 输入序列长度。我们在相同工作负载参数下，将启用 MTP 的性能与标准单 token 自回归解码基线（即禁用 MTP）进行比较。

如 Figure 22a 所示，我们观察到，在不同 batch size 下，启用单投机 token 的 MTP 相比非 MTP 基线可使解码吞吐量提升 6% 至 49%，且加速比在较小 batch size 下更为显著。这一现象的可能原因在于：较小 batch size 时，非 MTP 基线系统距离其峰值效率更远（例如，固定的每迭代开销难以被充分摊销），此时经 MTP 额外接受的 token（接受率 70%）带来更大的相对吞吐收益。随着 batch size



(a) Decode throughput.

(b) Decode latency breakdown (batch size 96).

Fig. 22. 采用与不采用 MTP 时的解码吞吐量与每层时延分解。所有实验的输入序列长度均为 4,096 token。在 (b) 中，“Overall”指两个微批次重叠后的每层时延，算子时延表示单个微批次的时延。

来源：p.45 C027（原文 Fig. 22）

增大，虽然 MTP 仍能带来绝对收益，但由于基线系统本身趋于饱和或 MTP 自身开销变得更加显著，其相对加速比可能减小。

然而，吞吐量的这一提升伴随着 MTP 启用时每个解码层迭代执行时延的增加。如 Figure 22b（batch size 为 96）所示，使用 MTP 使每层执行时延增加约 44%（例如从基线的 874 µs 增至启用 MTP 后的 1,260 µs）。这主要是因为每个启用 MTP 的 LLM 解码步要为每个请求处理来自上一次迭代的两个输入 token：一个基 token 和一个投机 token。每次迭代中更大的有效 batch size 自然导致 Attention Core、Gating、Dispatch、MoE 与 Combine 等核心操作的执行时间变长。

尽管每次迭代的时延有所增加，整体吞吐量仍得到提升。投机 token 以 70% 的接受率成功通过验证，意味着平均每个启用 MTP 的迭代可产出 1.7 个 token（1 个基 token + 0.7 个投机 token）。每迭代 token 数上的收益超过了约 44% 的迭代时间增幅，证实了我们的 MTP 实现对 CloudMatrix384 上 4K 序列长度负载具有净正向收益。

5.4.3 上下文缓存

§4.4 引入的 *EMS-上下文缓存*机制通过存储并复用先前请求的 KV 缓存块来加速 prefill 阶段。本消融研究定量评估 EMS-上下文缓存在 CloudMatrix384 上的有效性，尤其关注底层网络 fabric 对缓存访问性能的影响。具体而言，我们以 4K token 长度的输入以及每 NPU 总计 16K token 的批次大小，度量 prefill 吞吐量与首 token 时间（TTFT）。为评估不同缓存命中率下的性能，我们调整 token 复用率，该参数控制历史 KV 前缀被复用的比例。本研究的一个核心目标是比较两种网络配置下的 EMS 性能：一种利用高带宽 UB 互连，另一种回退到较慢的 VPC 网络平面进行缓存访问。

Figure 23 展示了这些不同 EMS 配置下性能随 token 复用率变化的趋势。如 Figure 23a 所示，两种网络配置下吞吐量与复用率均呈强正相关。对于基于 UB 的 EMS，复用率从 12.5% 提高到 50% 使 prefill 吞吐量提升 1.42 ×；在 90% 复用率下，吞吐量相较无 EMS 的基线提升 2.28 ×。这一显著改善的原因在于，更高的复用率意味着输入序列 KV 缓存中

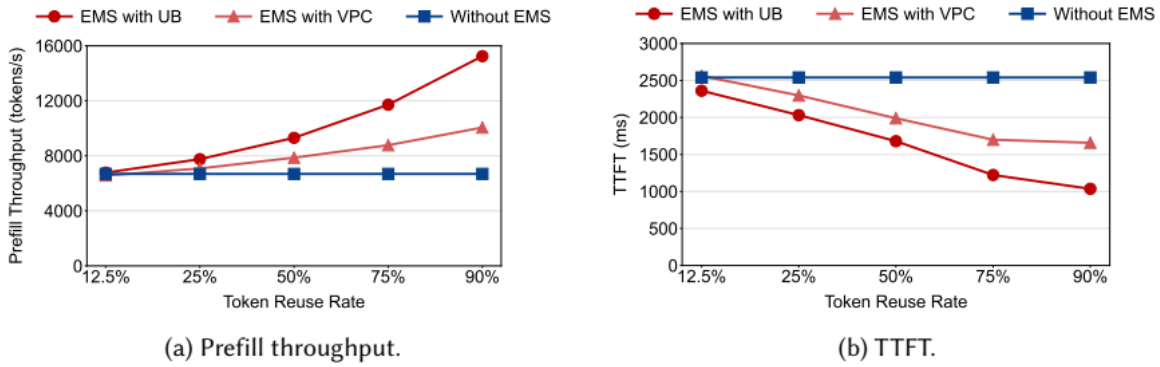


Fig. 23. 采用不同配置的 EMS 上下文缓存（EMS-Context Caching）时的整体 prefill 吞吐量与首 token 时间（TTFT）。

来源：p.46 C028（原文 Fig. 23）

有更大比例可以直接从 EMS 缓存加载而无需重新计算，从而显著降低 prefill NPU 上的计算负载。此外，对比两种网络配置，基于 UB 的 EMS 始终优于基于 VPC 的 EMS：使用 UB 平面最多可将 prefill 吞吐量提升 1.52 ×。这一收益直接归因于 UB 平面显著更高的带宽和更低的时延，它加速了 KV 缓存块从分布式 EMS 缓存向 NPU 的加载。

与此同时，如 Figure 23b 所示，TTFT（首 token 时间）随 token 复用率提高而显著下降。例如，对于基于 UB 的 EMS，50% 的 token 复用率使 TTFT 相比无上下文缓存减少 861 ms（34%），而 90% 复用率带来 1,505 ms（59%）的降幅。TTFT 的这一显著降低是缓存命中时跳过大量 prefill 计算的直接结果。快速从 EMS 加载历史 KV 缓存的能力——特别是在经由高带宽 UB 平面访问、且可能由分离式内存池的 DRAM 层提供服务时——直接转化为更快的首 token 生成。同样地，在所有复用率下，经由 UB 平面访问 EMS 缓存的 TTFT 均持续低于 VPC 平面，凸显了高性能互连对时延敏感型缓存检索的重要性。

5.5 算子性能

理解基本计算与通信算子的性能，是诊断系统瓶颈、指导软件优化的关键。本小节给出与 LLM 推理服务相关的关键算子的微基准分析，具体涵盖 MoE 通信原语、MLA 计算以及通用矩阵乘（GEMM）内核。我们在 CloudMatrix384 上（按每 Ascend 910 芯粒计）评估其性能，并与 NVIDIA H800 GPU 上的代表性性能进行对比。

5.5.1 通信算子

我们在 CloudMatrix384 上使用 CANN 实现对关键 MoE 通信算子（具体为 Dispatch 与 Combine）进行基准测试。该实现的细节见我们关于融合通信算子的设计（§4.2.1）。性能对比对象为 DeepSeek 的 DeepEP 实现在 NVIDIA H800 GPU 上的表现 [56]，如 Table 6 所示。表中给出从 8 到 256 个 rank 的各种专家并行度（#EP）下的时延与每 rank 达成带宽，每 rank 批大小为 128。

Operator	#EP	DeepSeek DeepEP on H800 [56]		CANN EP on CM384	
		Latency (μs)	Bandwidth (GB/s)	Latency (μs)	Bandwidth (GB/s)
Dispatch	8	163	46	116	71
	16	173	43	131	63
	32	182	41	133	62
	64	186	40	141	58
	128	192	39	152	54
	256	194	39	152	54
Combine	8	318	46	118	131
	16	329	44	132	117
	32	350	41	146	105
	64	353	41	150	103
	128	369	39	150	103
	256	360	40	149	103

Table 6. 不同专家并行（EP）度数下，NVIDIA H800（RDMA）与 CloudMatrix384（UB 平面）上 Dispatch 与 Combine 操作的通信算子性能（每个 rank 的时延与带宽）。

来源：p.47 C029（原文 Table 6）

对于分发（Dispatch）操作，CloudMatrix384（CM384）上的 CANN EP 实现在所有测试的 EP 度下均比 H800 上的 DeepEP 表现出更低的时延。

例如，在 EP 度为 8 时，CM384 的时延为 116 μs，而 H800 为 163 μs。随着 EP 度增大，CM384 的时延优势持续保持：EP256 下 CM384 为 152 μs，H800 为 194 μs。在 Dispatch 的每 rank 带宽方面，CM384 在较小 EP 度下表现更优（例如 EP8 下 71 GB/s 对 46 GB/s）。然而，在较大 EP 度下，我们观察到 CANN EP 在 CloudMatrix384 上的有效带宽显著下降。这一退化凸显了当前 EP 实现中的可扩展性瓶颈，我们将其留作未来的优化方向。

合并（Combine）操作则显示出 CANN 在 CM384 上更为显著的性能优势：在所有 EP 规模下，CM384 的时延均明显更低。例如，EP8 时 CM384 的时延为 118 μs，而 H800 为 318 μs；这一大幅时延优势一直保持到 EP256（CM384 为 149 μs，H800 为 360 μs）。此外，CM384 上 Combine 达到的每 rank 带宽也显著高于 H800：EP8 时 CM384 每 rank 达 131 GB/s，几乎是 H800 所达 46 GB/s 的三倍。这一带宽优势在所有测试的 EP 度下均保持，EP256 时 CM384 仍提供强劲的每 rank 103 GB/s，而 H800 为 40 GB/s。

这些结果凸显了 CANN 集合通信库的效率，以及 CloudMatrix384 的 UB 平面在应对 MoE 特有通信模式方面的高性能能力。CloudMatrix384 上持续更低的时延与更高的每 rank 带宽，对于缓解大规模专家并行所固有的通信瓶颈至关重要。

5.5.2 MLA 算子

我们在 CM384 上评估 CANN MLA 实现的 TFLOPS 利用率与内存带宽利用率，对比 DeepSeek FlashMLA 在 NVIDIA H800 上的表现，覆盖计算密集与内存密集两种设置。

Table 7 给出了负载以计算受限为主时 MLA 算子的 TFLOPS 利用率。H800 上的 DeepSeek FlashMLA 达到 66.7% 的计算利用率；我们在 CloudMatrix384 上的 CANN MLA 同样以 BF16/FP16 运行，达到了相当的 65.4% 利用率。这表明在计算密集场景下，两个平台对 MLA 可用算力的利用效率处于相近水平。

Operator Implementation	Precision	Compute Utilization (%)
DeepSeek FlashMLA on H800	BF16/FP16	66.7
CANN MLA on Ascend 910 die	BF16/FP16	65.4

Table 7. 计算密集场景下 MLA 算子在 NVIDIA H800 与单颗 Ascend 910 芯粒（CloudMatrix384）上的利用率（BF16/FP16 精度）。

来源：p.48 C030（原文 Table 7）

5.5.3 GEMM 算子

Operator Implementation	Utilization
DeepSeek FlashMLA on H800	89.6%
CANN MLA on Ascend 910 die	84.1%

In memory-intensive settings, the efficiency of utilizing available memory bandwidth is paramount. Table 8 shows this comparison. The DeepSeek FlashMLA on H800 achieves an 89.6% utilization of its hardware memory bandwidth. Our CANN MLA implementation on CloudMatrix384 achieves a similarly high utilization of 84.1%.

Table 8. 访存密集场景下 MLA 算子在 NVIDIA H800 与单颗 Ascend 910 芯粒（CloudMatrix384）上的内存带宽利用率。

来源：p.48 C031（原文 Table 8）

通用矩阵乘（GEMM）是几乎所有深度学习模型的基础计算内核。GEMM 运算（尤其是 INT8 等较低精度下）的效率对实现高推理吞吐量至关重要。我们对 CANN 提供的 INT8 GEMM 内核在单个 Ascend 910 芯粒（位于 CloudMatrix384 系统内）上的性能进行基准测试，覆盖一系列矩阵维度。结果详见 Table 9，展示了实际达成的计算利用率与运算期间的持续内存带宽。这些测试采用常用的 GEMM 分块维度（BM × BN = 128 × 152），运算输入为 INT8、输出为 BF16。

Groups	M	N	K	Memory Bandwidth (GB/s)	Compute Utilization (%)
4	7168	4096	4096	260	79.4
4	2048	7168	4096	325	77.4
4	7168	4096	8192	195	82.7
4	2048	7168	8192	266	81.1
8	7168	4096	4096	261	79.6
8	2048	7168	4096	327	77.9

needs of emerging workloads. In this section, we discuss potential future directions for both the CloudMatrix architecture and the LLM serving systems built upon it, aiming to further enhance scalability, flexibility, efficiency, and performance.

Table 9. 在不同配置下，单颗 Ascend 910 芯粒（CloudMatrix384）上 INT8 GEMM（通用矩阵乘）达到的内存带宽与计算利用率，采用 INT8 输入与 BF16 输出。分块（Tiling）：BM × BN = 128 × 152。

来源：p.49 C032（原文 Table 9）

如 Table 9 所示，Ascend 910 芯粒上的 CANN INT8 GEMM 算子在各种矩阵形状（M、N、K）与分组数下均表现出持续的高计算利用率，范围从 77.4% 到 82.7%。例如，在 4 个分组、维度 M=7168、N=4096、K=8192 时，该算子达到 82.7% 的利用率。这种高效率在不同配置下均得以保持，表明 Ascend 910 芯粒上 INT8 计算单元的稳健性能。

该表还给出了这些 GEMM 操作期间达到的持续内存带宽，范围为 195 GB/s 至 327 GB/s。这些数值远低于 Ascend 910 芯粒的峰值内存带宽。这一观察与高计算利用率相结合，有力地表明在所测试的矩阵维度下，这些 INT8 GEMM 操作主要受计算限制而非内存带宽限制。这一特性表明数据在 NPU 内部缓存层次与寄存器中得到了高效复用，使计算单元能够在接近峰值能力的水平上运行，而不会持续因来自内存的数据传输供给不足而受限。6 未来方向的讨论 AI 模型的快速演进及其无处不在的应用，持续对 AI 基础设施提出日益严苛的要求。虽然 CloudMatrix384 标志着紧耦合 AI 计算扩展的一个重要架构里程碑，但要满足

6.1 CloudMatrix 的未来演进

CloudMatrix384 所体现的超节点概念可沿多个维度延展，以承载未来的 AI 工作负载。

6.1.1 VPC 平面与 RDMA 平面的统一

如 §3.2 所述，CloudMatrix384 目前为 scale-out（RDMA）流量与 VPC 流量采用相互独立的网络平面。然而，CloudMatrix 使将 scale-out 通信整合入 VPC 网络成为可能。在典型的 AI 训练与推理工作负载中，带宽密集的通信阶段（如张量、专家与序列并行 TP/EP/SP）主要集中在超节点内部；与之相对，跨超节点通信主要源自数据并行与流水线并行（DP/PP），其带宽需求通常低得多。借助层次化 DP 通信与通信隐藏技术，VPC 网络足以满足大多数 AI 工作负载的超节点间通信需求。

基于这一观察，以 VPC 平面为基础的统一网络架构可以支撑构建可用区（AZ）规模的大型 AI 集群。它能够容纳多代异构的 AI 硬件，以超节点为基本单元实现灵活、模块化的扩展，并借助数据中心网络（DCN）技术支持跨区域的无缝互联。

6.1.2 更大规模的超节点

尽管 CloudMatrix384 以 384 个 NPU 提供了可观的规模，但预计下一代 AI 模型与应用场景将需要更大规模的超节点。推动这一规模增长趋势的关键因素包括：

1) 扩容以匹配模型演进：随着 LLM 的参数规模与架构复杂度持续攀升，支撑其推理服务的基础设施也必须相应演进。未来的模型预计将具有大得多的参数量、更长的输入序列以及数量更多的稀疏激活专家（在 MoE 设计中尤为明显）。这些趋势对每次推理会话中的算力、内存和互连带宽提出了越来越高的要求。此外，新兴的架构模式——例如面向专门推理的模块化子网络、检索增强生成或稠密–稀疏混合计算——要求模型组件之间更紧密的耦合，导致模型内通信与同步增多。要高效支撑这些工作负载，就需要将算力与内存共同部署在单个紧密集成的超节点内，以最小化通信时延并维持

高吞吐量。因此，扩大超节点容量不仅对满足原始资源需求至关重要，也是维持下一代 LLM 所要求的细粒度局部性与性能特征的必要条件。

2) 提升资源分配效率：扩大超节点规模还能在真实世界的异构负载条件下提升全系统的资源利用率。我们基于真实生产 trace，将每个 AI 任务建模为一组*紧耦合块*，以此模拟未来的 NPU 请求模式，其中每个块是必须在单个超节点内完成供给的一段连续 NPU，以满足作业内部的带宽与时延约束。如 Figure 24 所示，在很宽的平均块大小范围内，更大的超节点始终能取得更高的 NPU 分配率。例如，平均块大小为 10.08 时，384-NPU 超节点的分配率超过 94%，而 224-NPU 超节点则降至 91% 以下。这一改善源于碎片减少与更优的统计复用——更大的资源池为大小不一的作业提供了更高的放置灵活性。反之，在超节点规模固定时，块大小增大会因装箱困难而降低分配效率：当平均块大小达到 11.28 时，224-NPU 超节点的分配率跌破 85%。这些结果突出表明，在真实负载分布下，扩大超节点规模能显著提升系统吞吐量与效率。

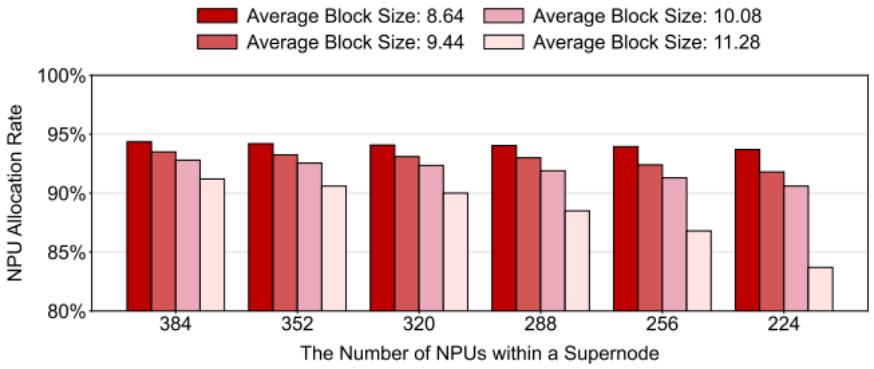


Fig. 24. 不同超节点规模与紧耦合块大小下的 NPU 分配率。

来源：p.50 C033（原文 Fig. 24）

3) 近乎恒定的摊销网络成本：扩大超节点规模本身并不会推高每 NPU 的网络成本。在网络架构相同（例如两层类 Clos 交换拓扑）的前提下，只要配置能够实现交换机端口的完全利用，不同超节点规模下每 NPU 摊销的网络基础设施成本几乎保持不变。如 Table 10 所示，192、288 或 384 NPU 的配置均实现 100% 的交换机利用率，每 NPU 摊销的交换机成本相同；而 256 或 352 NPU 等中间配置则存在交换机利用不足的问题，会略微抬高单节点成本。这些结果表明，将超节点规模扩展到给定交换层级的上限并不会引入额外的成本开销，从网络角度看是一种高性价比的策略。

Supernode Scale (# of NPUs)	# of Nodes	# of Switches	Switch Utilization
384	48	56	100%
352	44	56	92%
288	36	42	100%
256	32	42	89%
192	24	28	100%

Table 10. 不同超节点规模下的交换机利用率。注意，每个逻辑交换机由两颗物理交换芯片组成，如 §3.3.3 所述。

来源：p.51 C034（原文 Table 10）

4) 容纳更高的资源异构性：未来的 AI 工作负载将要求在同一执行上下文中获得越来越多样化的硬件支持。除 NPU 与 CPU 之外，下一代超节点还可能纳入面向物理模拟、实时视频处理、无损数据压缩和密码计算等任务的专用加速器。这些单元正日益成为端到端 AI 流水线中不可或缺的组成部分，在多模态或特定领域应用中尤为如此。要高效利用这类异构资源，它们必须共享同一高带宽、低时延的互连网络，并在超节点内以一等计算对等体的身份被访问。要在规模化场景下支撑这种多样性，既需要

更大的超节点规模，也需要更灵活的互连架构，这进一步强化了向更大、更异构、能够处理紧耦合跨功能 AI 工作负载的计算域演进的趋势。

6.1.3 CPU 的物理分离与池化

当前 CloudMatrix384 超节点通过池化各计算节点的 CPU 与 NPU（每节点集成 4 个鲲鹏 CPU 与 8 个 Ascend NPU），已实现一定程度的资源灵活性；而 CloudMatrix 架构未来的一个关键方向，是对 CPU 与 NPU 资源实施更根本性的 *物理分离式设计*，如 Figure 1 所示。这设想出一种由不同专用节点类型构建的超节点：以 NPU 为中心、密集搭载 AI 加速器的节点，以及以 CPU 为中心、提供充足通用算力、内存容量与 I/O 能力的节点。这些异构节点类型将通过高带宽、低时延的 UB 网络平面互联，在超节点层面实现细粒度、灵活且可扩展的资源池化。

物理分离的动机源自固定节点配置中传统 CPU-NPU 配对的僵化：静态的 NPU 与 CPU 配比制约了系统匹配负载需求的能力。例如，某些推理负载需要密集的 CPU 前后处理或大容量内存支撑的缓存，导致 NPU 空闲时却出现 CPU 瓶颈；反过来，训练负载可能使 NPU 饱和，CPU 资源却利用不足。在这些情形下，紧耦合的 CPU-NPU 配置会导致欠优的硬件利用率和僵化的扩展能力。

尽管 CloudMatrix384 的对等 UB 拓扑已经解耦了逻辑资源分配，使 CPU 与 NPU 可以在整个超节点内灵活配对，但将 CPU 和 NPU 资源物理分离为各自的专用资源池还能带来更多优势：

1) 独立且经过优化的扩展：可以发展物理上分离的以 NPU 为中心的节点（例如仅保留用于基本管理的最小本地 CPU，但将 NPU 密度最大化）和以 CPU 为中心的节点（例如配备大量 CPU 核心、大容量 DRAM 与丰富的 I/O 选项，充当超节点的主 CPU 与内存资源池）。这样，超节点的 NPU 算力与通用 CPU/内存容量便可独立地、也更经济地各自扩展。数据中心运营商进而可以组合出 NPU 与 CPU/内存配比高度可变的超节点，精确适配主导性负载（例如面向训练采用高 NPU 配比，面向数据密集型预处理或大规模 EMS 缓存采用高 CPU/内存配比）。

2) 更高的资源利用率与专用化：专用节点设计便于针对其主要资源类型做专门的硬件优化。NPU 节点可以专注于加速器的供电与散热，而 CPU/内存节点则可针对内存密度、I/O 带宽或特定 CPU 指令集进行优化。与一刀切的混合节点设计相比，这能为每种资源类型带来更好的整体效率与性能。

6.2 推理服务系统的未来增强

随着底层超节点架构持续演进，LLM 推理服务系统必须协同演进，方能充分利用这些能力。一个关键方向是超越粗粒度分离（如 prefill-解码分离），走向更细粒度的组件级分离式设计与智能自适应部署策略。这些方法旨在提升资源利用率、提高吞吐量，并支撑日益异构的工作负载与硬件配置。

6.2.1 组件级分离

CloudMatrix384 所采用的 prefill-解码-缓存分离（PDC 分离）对等推理服务架构，已被证明能有效分离 LLM 推理的主要阶段。然而，通过将模型执行进一步分解为可独立管理、部署与扩展的更细粒度组件，仍有进一步改进空间。我们着重指出两个新兴方向：

1) 解码-注意力分离与卸载：prefill 实例受算力约束、解码实例常受内存约束，而 Adrenaline 系统 [37] 表明，通过将内存密集型的注意力计算从解码路径中分离出来，并卸载到利用不足的 prefill 实例上，可以获取额外的性能收益。这一做法提升了整体内存带宽利用率，并使解码实例能够采用更大的 batch size，从而提高计算效率。它依赖于低时延同步、对被卸载任务的谨慎共置以及 SLO 感知的卸载策略。其结果是在不牺牲时延的前提下提升了吞吐量，展示了注意力分离如何在既有推理服务部署中释放潜在容量。

2) 注意力与 MoE 分离：大规模 MoE 模型因专家稀疏激活与极高的内存需求而带来独特挑战。MegaScale-Infer [59] 提出将注意力组件与专家组件分离为各自独立的执行服务，从而支持不同的并行策略与硬件映射。需要处理每一个 token 的注意力层以数据并行（DP）方式部署在内存优化的节点上，而专家 FFN 则经由专家并行（EP）分布到专用资源池中。这种分离式执行减少了争用、提升了吞吐量，并允许注意力资源与专家资源独立扩展，这对高效服务万亿参数级 MoE 模型至关重要。

这些分离技术共同代表了一种转变：将 LLM 视为一组松耦合的微服务集合，每个微服务拥有各自独特的性能特征。这种粒度使负载能更好地映射到异构硬件，并改善超节点范围内的负载均衡与可扩展性。

6.2.2 混合与自适应部署

一旦 LLM 推理被分解为可视为细粒度微服务的组件——例如注意力执行、FFN 计算、KV 缓存管理或 MoE 专家门控——推理服务系统便获得采用更复杂部署策略的高度灵活性。这类混合与自适应部署模式使系统能够按各组件独特的计算与内存需求定制资源分配，从而提升整体利用率与可扩展性。

1) 硬件感知的微服务放置：每个微服务都可以依据其性能特征映射到最合适的硬件类型。例如，通常受内存带宽约束的注意力层应优先放置在内存吞吐量高的 NPU 上；计算密集的 FFN 模块受益于分配到算力强大的 NPU；而轻量级或时延不敏感的操作（如 KV 缓存索引）则可以卸载到

池化的 CPU 或成本更低的通用加速器上。这种细粒度匹配能更高效地利用异构硬件，并在不损害性能的前提下降低成本。

2) 微服务混合共置：分离后的微服务还可以动态共置，以提升整个超节点的资源利用率。例如，解码阶段受内存约束的注意力操作可以卸载到内存利用不足的 prefill 实例上 [37]。这类混合共置策略有助于缓解资源瓶颈、改善各阶段的利用率，并提高有效系统吞吐量，在波动或突发性负载下尤其如此。

3) 微服务的自适应独立扩展：微服务分离的一项关键优势在于能够根据实时负载特征独立扩展每个组件。例如，在处理长上下文输入期间，注意力微服务可能承受更高负载，可以相应地单独扩展，而无需追加 FFN 或专家资源。这种粒度避免了系统性的过度预配，使系统能够弹性适应负载动态。

要充分释放这些能力，推理服务基础设施必须引入一个完善的编排层，持续剖析系统负载、预测性能瓶颈，并做出实时的、SLO 感知的调度与扩展决策。该编排器充当混合部署模型的控制平面，确保即便负载与资源可用性发生波动，性能保障仍能得到满足。

综上所述，以组件级分离为基础的混合与自适应部署策略代表了 LLM 推理服务系统设计中一个富有前景的前沿方向。它们能够实现更精确的资源利用、跨异构硬件的无缝负载均衡，并具备满足日益复杂多样的模型架构所带来的未来需求的能力。

7 结论

7 结论 本文介绍了 Huawei CloudMatrix——一种体现华为先进 AI 基础设施愿景的下一代 AI 数据中心架构。我们重点介绍了 Huawei CloudMatrix384，即这一创新架构理念的首个生产级实现。CloudMatrix384 是为高效支撑大规模 AI 工作负载而打造的 AI 超节点，采用全对等互连的硬件设计。它通过超高带宽、低时延的统一总线（UB）网络互连 384 个 Ascend 910 NPU 与 192 个鲲鹏 CPU。这一独特的架构便于动态资源池化、简化的内存管理以及卓越的节点间通信，有效解决了传统数据中心架构中常见的可扩展性与效率难题。

基于 CloudMatrix384，我们提出了 CloudMatrix-Infer——一套完整的推理服务解决方案，采用对等的推理服务架构，将推理工作流分离为 prefill、解码与缓存三个独立子系统。该架构通过让所有 NPU 统一访问共享的分离式内存池，显著简化了调度、增强了负载均衡并优化了资源利用率。我们进一步设计并实现了多项先进的硬件感知技术，包括大规模专家并行（LEP）、优化的通信与 MLA 算子、基于微批次的流水线以及 INT8 量化。这些技术共同提升了 MoE 与 MLA 计算吞吐量、改善了缓存效率，并带来整体推理性能的大幅提升。

我们使用 DeepSeek-R1 模型开展的大量评估表明，CloudMatrix-Infer 取得了出色的吞吐量：prefill 阶段每 NPU 达到 6,688 tokens/s，解码阶段每 NPU 达到 1,943 tokens/s，同时始终保持每个输出 token 低于 50 ms 的低时延。这两项结果对应的计算效率分别为 prefill 4.45 tokens/s/TFLOPS 与解码 1.29 tokens/s/TFLOPS，两者均超越了领先者公开的效率

——超过 NVIDIA H100 上 SGLang 与 H800 上 DeepSeek 已发表的效率水平。此外，CloudMatrix-Infer 还能有效管理吞吐-时延权衡，在更严格的 sub-15 ms TPOT 约束下仍能维持 538 tokens/s 的吞吐。INT8 量化策略则在一系列 benchmark 上保持了与 DeepSeek 官方 API 相当的精度。

展望未来，仍有多个令人期待的方向可进一步增强 CloudMatrix384。未来工作包括：整合并统一 VPC 与 RDMA 网络平面以实现更顺畅的互连、扩展到更大规模的超节点配置，以及更深入地对 CPU 资源进

行分离与池化。此外，更细粒度的组件级分离与自适应部署策略，也是让 AI 数据中心基础设施获得更高灵活性、效率与可扩展性的有力方向

总而言之，我们的结果验证了华为 CloudMatrix 是一个高效、可扩展且经过性能优化的平台，适合部署大规模 AI 工作负载，并为未来的 AI 数据中心基础设施树立了标杆。

参考文献

参考文献